


Báo cáo tiến độ

Ngày 25 tháng 9 năm 2026



Hình 1. Sơ đồ tổng quan hệ thống, giải quyết đồng thời hai bài toán: phân loại loại thực phẩm, và đánh giá an toàn (An toàn / Vượt ngưỡng) đối với từng loại thuốc trừ sâu. Cả hai bài toán đều dùng chung Mô-đun Phân loại, một thành phần có thể thay thế bằng các kiến trúc độc lập – XGBoost, LightGBM, SMART-NIR (cả hai bài toán) và GuidedDCNet (chỉ bài toán phân loại thực phẩm; Mục 1.2). Bài toán (2) lặp lại độc lập cho từng loại trong 19 thuốc trừ sâu khảo sát theo cascade hai bước: Bước 1 phát hiện có/không, Bước 2 (chỉ chạy nếu Bước 1 xác định có) phân loại An toàn/Vượt ngưỡng theo MRL của đúng cặp (thực phẩm, thuốc trừ sâu); loại thực phẩm dự đoán được (hoặc nhãn thật khi huấn luyện) là một đầu vào bổ sung cho cả hai bước, vì MRL phụ thuộc vào loại thực phẩm (Mục 2.0.1). Mỗi mô hình được huấn luyện theo kiểm định chéo K-Fold (K-Fold cross-validation, $K=5$); dự đoán cuối cùng của một mẫu tổng hợp từ 5 mô hình theo fold bằng bỏ phiếu đa số (majority voting). Kết xuất cuối cùng của hệ thống tổng hợp cả 20 mô hình (1 phân loại thực phẩm + 19×2 an toàn thuốc trừ sâu) qua một phép hợp logic đơn giản, không cần huấn luyện thêm.

1. Phương pháp

1.1. Tổng quan

Hệ thống được xây dựng nhằm giải quyết đồng thời hai bài toán phân loại từ cùng một phổ NIR đầu vào của một mẫu rau củ quả: (1) phân loại loại thực phẩm; và (2) đánh giá mức độ an toàn thực phẩm của mẫu đối với từng loại trong số 19 thuốc bảo vệ thực vật khảo sát, phân vào một trong hai mức – *An toàn* (không phát hiện thuốc trừ sâu, hoặc có phát hiện nhưng nồng độ không vượt Ngưỡng dư lượng tối đa cho phép, Maximum Residue Limit – MRL) và *Vượt ngưỡng* (có phát hiện và nồng độ vượt MRL). Vì MRL phụ thuộc vào cả loại thực phẩm lẫn loại thuốc trừ sâu, ngưỡng dùng để gán nhãn cho bài toán (2) được tra theo đúng từng cặp (thực phẩm, thuốc trừ sâu) của mẫu, thay vì một ngưỡng cố định chung cho mọi thực phẩm (Mục 2.0.1). Sơ đồ tổng quan của hệ thống được minh họa trong Hình 1.

Bài toán (1) được giải quyết bằng **Mô-đun Phân loại** (Mục 1.2) đóng vai trò bộ phân loại đa lớp, với số lớp đầu ra tương ứng số loại rau củ quả (9 lớp). Bài toán (2) được giải quyết theo một quy trình lai gồm hai bước nhị phân theo tầng (cascade), lặp lại độc lập cho từng loại trong số 19 thuốc trừ sâu khảo sát, và cũng tái sử dụng nguyên vẹn Mô-đun Phân loại cho cả hai bước:

- **Bước 1 – Phát hiện.** Phân loại nhị phân xác định thuốc trừ sâu đang xét có tồn tại trong mẫu hay không. Huấn luyện trên toàn bộ mẫu.
- **Bước 2 – Phân loại mức độ.** Phân loại nhị phân trực tiếp giữa *An toàn* và *Vượt ngưỡng* theo đúng MRL của cặp (thực phẩm, thuốc trừ sâu) của mẫu đó. Khác với một cascade thuần túy, Bước 2 huấn luyện trên *toàn bộ* mẫu chứ không chỉ tập con Bước 1 xác định là có phát hiện: mẫu không phát hiện được gán thẳng nhãn An toàn (giống mẫu có phát hiện nhưng dưới MRL), giúp

Bước 2 mạnh và ổn định ngay cả khi được hỏi độc lập. Ở suy luận, Bước 2 chỉ thực sự được gọi đến khi Bước 1 xác định có phát hiện, đúng theo cascade Bước 1 – Bước 2 (Mục 3.2.2).

Chỉ có hai nhãn an toàn cuối cùng – *An toàn* và *Vượt ngưỡng* – không có mức trung gian riêng: một mẫu không được Bước 1 phát hiện, hoặc được Bước 1 phát hiện nhưng Bước 2 xác định dưới MRL, đều được xem là *An toàn*.

Cả 20 mô hình (1 cho bài toán (1), 19×2 cho bài toán (2)) đều huấn luyện theo kiểm định chéo K-Fold ($K=5$, Mục 3.1.2 và Mục 3.2.2), tạo ra 5 mô hình độc lập theo từng fold; ở bước suy luận, dự đoán cuối cùng cho một mẫu được tổng hợp từ 5 mô hình này bằng bỏ phiếu đa số (majority voting) thay vì chỉ dùng một mô hình đơn lẻ, giúp giảm phương sai và tăng độ ổn định của kết quả. Vì cả hai bài toán đều là bài toán phân loại thuần túy, chúng được đánh giá trên các phương pháp cơ sở độc lập – XGBoost, LightGBM, SMART-NIR (cả hai bài toán) và GuidedDCNet (chỉ bài toán phân loại thực phẩm) – trình bày chi tiết ở Mục 1.3, 1.4 (XGBoost, LightGBM) và Mục 1.2 (SMART-NIR, GuidedDCNet). Vì loại thực phẩm ảnh hưởng trực tiếp tới ngưỡng MRL dùng để gán nhãn ở Bước 1 và Bước 2, thông tin này được đưa thêm vào làm đặc trưng đầu vào tường minh (one-hot theo 9 loại thực phẩm, nối vào đặc trưng phổ trước khi vào mô hình) cho cả ba kiến trúc ở hai bước này, thay vì buộc mô hình phải tự suy luận loại thực phẩm chỉ từ hình dạng phổ.

Cách tiếp cận theo tầng (cascade) cho bài toán (2) mang lại hai lợi ích: (i) phản ánh đúng quy trình phân tích thực tế, trong đó bước sàng lọc sự hiện diện luôn được thực hiện trước bước đánh giá mức độ; và (ii) cho phép đánh giá độc lập độ chính xác của từng giai đoạn – phát hiện và phân loại mức độ – thay vì gộp chung thành một chỉ số duy nhất. Vì Bước 2 huấn luyện trên toàn bộ mẫu (không chỉ tập con

Bước 1 xác định có phát hiện), cascade ở đây chủ yếu thể hiện ở suy luận (Bước 2 chỉ thực sự được hỏi khi Bước 1 báo có), không phải ở việc chia tách tập huấn luyện.

Kết xuất cuối cùng của hệ thống cho một mẫu gồm ba thành phần, tổng hợp từ 20 mô hình trên: (i) loại thực phẩm (đầu ra bài toán (1)); (ii) trạng thái an toàn tổng thể – *An toàn* nếu cả 19 cặp Bước 1–Bước 2 của bài toán (2) đều kết luận An toàn, ngược lại *Không an toàn* nếu có ít nhất một thuốc trừ sâu bị kết luận Vượt ngưỡng; và (iii) khi không an toàn, danh sách cụ thể các thuốc trừ sâu bị kết luận Vượt ngưỡng (không chỉ một cờ nhị phân duy nhất). Vì 19 cặp mô hình của bài toán (2) độc lập với nhau và mỗi cặp tự quyết định đúng một thuốc trừ sâu, bước tổng hợp này không cần huấn luyện thêm: chỉ là phép hợp logic (logical OR) và liệt kê nhãn dương trên 19 kết luận cuối cùng (sau cascade Bước 1–Bước 2) của từng thuốc.

1.2. Mô-đun Phân loại

Bốn kiến trúc độc lập được cài đặt và đánh giá cho Mô-đun Phân loại, dùng chung cho cả bài toán (1) và bài toán (2): hai mô hình cây tăng cường theo gradient (Gradient Boosted Trees) đại diện cho hướng tiếp cận học máy cổ điển, XGBoost (Mục 1.3) và LightGBM (Mục 1.4); và hai kiến trúc mạng nơ-ron sâu, SMART-NIR (Mục 1.4) – kiến trúc chính của hệ thống – và GuidedDCNet (Mục 1.4.4), một kiến trúc đối chứng dựa trên mô hình khuếch tán (diffusion model) có hướng dẫn. Số lớp đầu ra thay đổi theo từng bài toán (9 lớp cho phân loại thực phẩm, nhị phân cho từng thuốc trừ sâu ở bài toán (2)), nhưng kiến trúc của mỗi phương pháp giữ nguyên.

1.3. Mô hình XGBoost

XGBoost (Extreme Gradient Boosting) là thuật toán học tập hợp (ensemble learning) thuộc họ Gradient Boosting Decision Trees (GBDT), được phát triển để khắc phục các hạn chế của Gradient Boosting truyền thống về hiệu năng, khả năng mở rộng và độ ổn định trên dữ liệu lớn, phức tạp – nhờ đó trở thành một trong những phương pháp phổ biến nhất cho bài toán phân loại và hồi quy.

Cốt lõi của XGBoost là ý tưởng tăng cường tuần tự (boosting): một tập hợp cây quyết định (weak learners) được huấn luyện tuần tự, mỗi cây mới học để bù đắp sai lệch mà các cây trước đó chưa dự đoán tốt, thay vì huấn luyện độc lập như bagging. Gọi y_i và $\hat{y}_i$ lần lượt là nhãn thực và giá trị dự đoán của mẫu i , hàm mục tiêu được tối ưu ở mỗi vòng lặp có dạng

$$L = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k), \quad (1)$$

trong đó $l(\cdot)$ là hàm mất mát đo độ sai lệch giữa y_i và $\hat{y}_i$, còn $\Omega(f_k)$ là số hạng điều chuẩn áp dụng cho cây thứ k (ký hiệu f_k), giúp kiểm soát độ phức tạp của cây và giảm nguy cơ quá khớp.

Khác với Gradient Boosting truyền thống chỉ dùng gradient bậc nhất, XGBoost tận dụng khai triển Taylor bậc hai của hàm mất mát – kết hợp cả gradient (đạo hàm bậc 1) và

Hessian (đạo hàm bậc 2) – giúp ước lượng chính xác hơn mức cải thiện khi thêm một cây mới, nhờ đó quá trình tối ưu hội tụ nhanh và ổn định hơn. Mỗi cây được xây dựng theo hướng tham lam, với tiêu chí chia nhánh dựa trên mức độ giảm của hàm mục tiêu, hỗ trợ cả chiến lược mở rộng theo chiều sâu (depth-wise) lẫn mở rộng theo nút mang lại lợi ích lớn nhất (leaf-wise), kèm cơ chế cắt tỉa dựa trên độ lợi (gain) để loại sớm các nhánh không mang lại cải thiện đáng kể.

Nhờ sự cân bằng giữa độ chính xác, khả năng diễn giải và hiệu năng tính toán, XGBoost được ứng dụng rộng rãi và đóng vai trò quan trọng trong hệ sinh thái học máy hiện đại.


1.4. Mô hình LightGBM

LightGBM (Light Gradient Boosting Machine) là một thuật toán Gradient Boosted Trees khác, cùng họ với XGBoost (Mục 1.3) nhưng khác biệt chủ yếu ở chiến lược phát triển cây và cách xử lý dữ liệu lớn, được đưa vào làm phương pháp cơ sở thứ hai để đối chứng độc lập với XGBoost trong cùng họ mô hình cây tăng cường.

Khác biệt đầu tiên nằm ở chiến lược phát triển cây: thay vì mở rộng theo chiều sâu (depth-wise, XGBoost mặc định), LightGBM mở rộng theo nút mang lại lợi ích lớn nhất trước (leaf-wise), chọn nút lá có mức giảm hàm mất mát lớn nhất để tách tiếp ở mỗi bước, thường hội tụ nhanh hơn và đạt độ chính xác cao hơn với cùng số nút lá, đổi lại dễ quá khớp hơn trên tập dữ liệu nhỏ nếu không giới hạn độ sâu tối đa.

Thứ hai, LightGBM dùng Gradient-based One-Side Sampling (GOSS) để giảm số mẫu cần quét ở mỗi vòng lặp: các mẫu có gradient lớn (mô hình hiện tại còn dự đoán sai nhiều) được giữ lại toàn bộ, trong khi chỉ một tỉ lệ nhỏ mẫu có gradient nhỏ được lấy mẫu ngẫu nhiên (kèm hệ số trọng số bù trừ để giữ ước lượng gradient không thiên lệch), giúp giảm đáng kể thời gian huấn luyện mà ít ảnh hưởng độ chính xác. Thứ ba, Exclusive Feature Bundling (EFB) gộp các đặc trưng thưa và loại trừ lẫn nhau (hiếm khi cùng khác không) thành một đặc trưng gộp duy nhất, giảm số chiều thực tế cần xử lý khi xây cây – đặc biệt phù hợp với đặc trưng one-hot loại thực phẩm (Mục 1.1) được nối thêm vào vector phổ cho Bước 1 và Bước 2, vốn thưa và loại trừ lẫn nhau theo đúng định nghĩa của one-hot encoding.

Kiến trúc SMART-NIR. Kiến trúc Vision Transformer (ViT) nắm bắt tốt đặc trưng toàn cục và dễ mở rộng, nhưng các mô hình ViT truyền thống thường dùng phép chiếu tích chập 3×3 ở bước nhúng đặc trưng, dễ làm mất các đặc tính tín hiệu quan trọng. SMART-NIR khắc phục hạn chế này bằng cách để mỗi token nắm bắt một tập đặc trưng tín hiệu phong phú hơn, thông qua bốn mô-đun nối tiếp minh họa trong Hình 2: (1) Khối Multi-kernel trích xuất đặc trưng thô từ phổ NIR ở nhiều tỉ lệ khác nhau; (2) Patch + Position Embedding mã hóa và định vị các đặc trưng thô thành chuỗi token; (3) Khối mã hóa Transformer tinh chỉnh chuỗi token thành đặc trưng giàu thông tin; (4) KAN đóng vai trò bộ phân loại ở đầu ra, với số lớp thay đổi theo từng bài toán con đích.



Hình 2. Kiến trúc mô hình SMART-NIR

1.4.1. Khối Multi-kernel

Phổ NIR đầu vào được biểu diễn dưới dạng vector $\mathbf{X} \in \mathbb{R}^{L \times C}$, với L là độ dài phổ (số bước sóng) và $C = 1$ là số kênh. Khối Multi-kernel gồm bốn nhánh tích chập song song với kích thước nhân lần lượt là 4×1 , 8×1 , 16×1 và 32×1 , cho phép trích xuất đặc trưng thô ở nhiều tỉ lệ khác nhau. Ở nhánh thứ i ($i \in \{1, 2, 3, 4\}$), một nhân tích chập $\mathbf{W}_i$ có kích thước $K_i = (C_{out}, K_w, K_h)$ – với C_{out} là số kênh đầu ra, K_w và K_h lần lượt là chiều rộng và chiều cao của nhân – được áp dụng lên $\mathbf{X}$ với bước nhảy chung $S = (4, 1)$ và đệm P_i riêng cho từng nhánh:

$$\begin{aligned} \mathbf{F}_1 &= \text{Conv}(\mathbf{X}, \mathbf{W}_1, K_1=(C_{out}, 4, 1), S, P_1=(0, 0)) \\ \mathbf{F}_2 &= \text{Conv}(\mathbf{X}, \mathbf{W}_2, K_2=(C_{out}, 8, 1), S, P_2=(3, 0)) \\ \mathbf{F}_3 &= \text{Conv}(\mathbf{X}, \mathbf{W}_3, K_3=(C_{out}, 16, 1), S, P_3=(7, 0)) \\ \mathbf{F}_4 &= \text{Conv}(\mathbf{X}, \mathbf{W}_4, K_4=(C_{out}, 32, 1), S, P_4=(15, 0)) \end{aligned} \quad (2)$$

Bốn đặc trưng thô $\mathbf{F}_1, \mathbf{F}_2, \mathbf{F}_3, \mathbf{F}_4$ được nối theo chiều kênh, tạo thành đầu ra $\mathbf{X}_0$ của khối Multi-kernel.

1.4.2. Patch + Position Embedding

Đặc trưng thô $\mathbf{X}_0$ được chuyển vị và làm phẳng theo chiều không gian để tạo thành chuỗi token, sau đó nối với một token phân loại học được $\mathbf{x}_{cls}$ và cộng thêm embedding vị trí học được $\mathbf{E}_{pos}$, tạo thành chuỗi đầu vào $\mathbf{X}_1$ cho khối mã hóa Transformer:

$$\mathbf{X}_1 = \text{Concat}(\mathbf{x}_{cls}, \mathbf{X}_0^T) + \mathbf{E}_{pos} \quad (3)$$

1.4.3. Khối mã hóa Transformer

Khối mã hóa Transformer nắm bắt các phụ thuộc phức tạp trong chuỗi token thông qua một chồng lớp, mỗi lớp gồm cơ chế tự chú ý đa đầu (Multi-Head Self-Attention – MHSA) nối tiếp một mạng truyền thẳng (feedforward), có chuẩn hóa lớp (Layer Normalization) trước mỗi khối và kết nối tắt (skip connection) để giảm hiện tượng tiêu biến gradient.

Tự chú ý đa đầu: Từ chuỗi đầu vào $\mathbf{X}_1 \in \mathbb{R}^{(H_{out}+1) \times C_{out}}$ (H_{out} là số token thô, chưa tính token phân loại), ba ma trận Query, Key, Value được tạo ra bằng phép chiếu tuyến tính học được: $\mathbf{Q} = \mathbf{X}_1 \mathbf{W}_Q$, $\mathbf{K} = \mathbf{X}_1 \mathbf{W}_K$, $\mathbf{V} = \mathbf{X}_1 \mathbf{W}_V$, với $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$ là các ma trận trọng số có

thể học. Trọng số chú ý giữa mỗi cặp token được tính bằng tích vô hướng chuẩn hóa giữa $\mathbf{Q}$ và $\mathbf{K}$, qua hàm softmax để phản ánh mức độ quan trọng tương đối của từng token trong chuỗi:

$$SA(\mathbf{X}_1) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{H_{out} + 1}}\right) \mathbf{V} \quad (4)$$

Cơ chế MHSA mở rộng tự chú ý (self-attention) chuẩn bằng cách thực hiện N_h phép tính chú ý song song, gọi là các đầu chú ý (head); mỗi đầu chiếu tuyến tính riêng để nắm bắt một khía cạnh quan hệ khác nhau trong dữ liệu, rồi các đầu ra được nối lại và biến đổi tuyến tính để tạo kết quả cuối cùng:

$$\begin{aligned} MHS A(\mathbf{X}_1) &= \text{Concat}(SA_1(\mathbf{X}_1), SA_2(\mathbf{X}_1), \\ &\quad \dots, SA_{N_h}(\mathbf{X}_1)) \end{aligned} \quad (5)$$

Dual-MLP: Để giảm chi phí tính toán mà vẫn duy trì, thậm chí cải thiện hiệu năng, token đầu ra $\mathbf{z}$ của khối MHSA được tách theo chiều cuối thành hai nửa bằng nhau $\mathbf{m}$ và $\mathbf{n}$, mỗi nửa đi qua một nhánh biến đổi tuyến tính riêng biệt rồi nối lại:

$$\begin{aligned} \text{DUAL-MLP} &= \text{Concat}(\mathbf{W}_{fc4} \text{GELU}(\mathbf{W}_{fc2} \mathbf{m}), \\ &\quad \mathbf{W}_{fc3} \text{GELU}(\mathbf{W}_{fc1} \mathbf{n})) \end{aligned} \quad (6)$$


với $\mathbf{W}_{fc1}, \mathbf{W}_{fc2}, \mathbf{W}_{fc3}, \mathbf{W}_{fc4}$ là các ma trận trọng số học được của bốn nhánh tuyến tính minh họa ở Hình 2. Việc xử lý song song hai nửa đặc trưng theo cách này giúp mô hình học được các mẫu đặc trưng đa dạng hơn mà không làm phát sinh chi phí tính toán đáng kể.

1.4.4. Bộ phân loại

Ở đầu ra, kiến trúc KAN đóng vai trò bộ phân loại, với hai lớp ẩn kích thước giảm dần (32, 16), như minh họa ở Hình 3. Khác với MLP truyền thống dùng trọng số tuyến tính cho mỗi kết nối, KAN thay thế các ma trận trọng số bằng các hàm một biến có thể học được, áp dụng độc lập theo từng chiều của đầu vào.

Kiến trúc GuidedDCNet. Khác với SMART-NIR (một mạng phân loại truyền thống, ánh xạ trực tiếp phổ NIR sang nhãn), GuidedDCNet tiếp cận bài toán phân loại theo hướng mô hình sinh: nhân $y^{(0)}$ được xem như biến cần khôi phục từ nhiễu Gauss thông qua một quá trình khuếch tán có điều kiện (conditional diffusion), tương tự Denoising Diffusion Probabilistic Models (DDPM). Kiến trúc gồm ba thành phần chính: (1) một bộ mã hóa dữ liệu trích xuất embedding $\pi(x)$ từ phổ đầu vào; (2) Cơ chế Hướng dẫn Điều kiện Đa tỉ lệ (Multi-scale Conditional Guidance Mechanism – MCGM), sinh đồng thời một vector hướng dẫn toàn cục $\hat{y}_g$ (trung bình bản đồ kích hoạt từ một nhánh mã hóa toàn cục) và một vector hướng dẫn cục bộ $\hat{y}_l$ (từ một tập con các vị trí bước sóng quan trọng nhất, được tổng hợp bằng gated-attention pooling); và (3) một mạng khử nhiễu Conditional UNet, ước lượng nhiễu đã thêm vào $y^{(0)}$ tại mỗi bước thời gian, có điều kiện theo cả $\pi(x)$ lẫn hai vector hướng dẫn.

Ở pha khuếch tán thuận, nhãn gốc được nhiễu hóa dần theo lịch trình tuyến tính $\{\beta_t\}_{t=1}^T$, kết hợp với hai vector



Hình 3. Kiến trúc mô hình KAN

định bằng phương pháp phân tích hóa học chuyên sâu trong phòng thí nghiệm. Phần này trình bày thống kê mô tả (EDA) trên từng máy: phân bố mẫu theo loại rau củ quả, tỉ lệ nhiễm từng loại thuốc trừ sâu, đặc điểm phổ NIR theo từng loại, và phân bố nồng độ trong các mẫu có phát hiện.

2.0.1. Ngưỡng MRL theo thực phẩm và thuốc trừ sâu

Ngưỡng dư lượng tối đa cho phép (Maximum Residue Limit – MRL) dùng để gán nhãn cho bài toán (2) (Mục 1.1) được tra theo một bảng ngưỡng hai chiều: mỗi cặp (loại thực phẩm, thuốc trừ sâu) trong số 9 loại thực phẩm và 19 thuốc trừ sâu khảo sát ứng với một giá trị MRL (mg/kg) riêng. Nhãn của bài toán (2) với một mẫu có nồng độ thực đo v , thuộc thực phẩm f và đang xét thuốc trừ sâu p , được xác định:

$$\text{nhãn}(v, f, p) = \begin{cases} \text{Vượt ngưỡng} & v \neq -1, v > \text{MRL}(f, p) \\ \text{An toàn} & \text{ngược lại} \end{cases} \quad (9)$$

2.1. Thống kê mô tả

Bảng 1. Thông số chung của hai máy quang phổ

Thông số	FLAMENIR	OCEANFX
Số lượng mẫu	335.805	380.029*
Số lượng bước sóng	128	2.136
Số lượng lớp phân loại	9	9
Số thuốc trừ sâu cần dự đoán	19	19

* đã loại 1 mẫu ngoại lai do lỗi cảm biến (quy trình lọc ngoại lai, Mục 3.2.1). Số mẫu đã loại các nhóm mẫu trùng phổ (cùng lần quét bị ghi nhận nhiều lần) mang nhãn mâu thuẫn hoặc khác loại thực phẩm, chỉ giữ một bản với nhóm trùng phổ đồng thuận nhãn, và chưa tính 100 mẫu mỗi máy được tách riêng làm tập kiểm tra độc lập cuối cùng.

Bảng 1 cho thấy sự đánh đổi giữa hai máy: OCEANFX có nhiều mẫu hơn FLAMENIR (380.029 so với 335.805) nhưng FLAMENIR có độ phân giải phổ thấp hơn nhiều (128 so với 2.136 điểm bước sóng) so với OCEANFX. Cả hai máy đều khảo sát cùng 9 loại rau củ quả và 19 thuốc trừ sâu, cho phép so sánh trực tiếp hiệu năng mô hình giữa hai cấu hình phân cứng khác nhau ở Mục 4.

Bảng 2. Số lượng mẫu theo loại rau củ quả

Loại	Số lượng mẫu	
	FLAMENIR	OCEANFX
Khổ Qua	41.652	45.883
Mồng Tơi	32.698	38.114
Cải Thừa	39.114	43.829
Cà Chua	38.059	45.828
Cải Bẹ Xanh	31.066	43.413
Dưa Leo	41.180	44.789
Xà Lách	32.713	35.598
Đậu Cove	38.869	42.116
Cà Rốt	40.454	40.459

Bảng 2 cho thấy phân bố mẫu giữa các loại rau củ quả không hoàn toàn cân bằng, dù mức mất cân bằng ở mức tương đối nhẹ. Trên FLAMENIR, chênh lệch giữa loại nhiều mẫu nhất (Khổ Qua, 41.652) và ít mẫu nhất (Cải Bẹ Xanh, 31.066) khoảng 1,34 lần; trên OCEANFX, mức chênh lệch tương tự, khoảng 1,29 lần giữa Khổ Qua

hướng dẫn:

$$y^{(t)} = \sqrt{\alpha_t} y^{(0)} + \sqrt{1 - \alpha_t} \epsilon + (1 - \sqrt{\alpha_t})(\hat{y}_g + \hat{y}_l), \quad (7)$$

với $\epsilon \sim \mathcal{N}(0, I)$, $\alpha_t = 1 - \beta_t$ và $\bar{\alpha}_t = \prod_{\tau \leq t} \alpha_\tau$. Mạng UNet có điều kiện g_θ được huấn luyện để ước lượng lại ϵ từ $y^{(t)}$, $\pi(x)$ và hai vector hướng dẫn, tối thiểu hóa đồng thời hàm mất mát ước lượng nhiễu (MSE) và hai số hạng điều chuẩn Maximum Mean Discrepancy (MMD) áp dụng riêng cho từng nhánh hướng dẫn:


$$\mathcal{L}_{total} = \|\epsilon - g_\theta(\pi(x), y^{(t)}, \hat{y}_g, \hat{y}_l, t)\|^2 + \lambda(\mathcal{L}_g^{MMD} + \mathcal{L}_l^{MMD}). \quad (8)$$

Ở bước suy luận, nhãn dự đoán $\hat{y}^{(0)}$ được khôi phục bằng một quá trình khuếch tán ngược đầy đủ T bước, xuất phát từ $y^{(T)} \sim \mathcal{N}((\hat{y}_g + \hat{y}_l)/2, I)$.

Nhánh cục bộ của MCGM xác định các vị trí bước sóng quan trọng nhất bằng độ nhạy gradient ($|\partial(\text{logits})/\partial x|$, giữ lại 30% vị trí có độ nhạy cao nhất) – một xấp xỉ nhanh cho vai trò diễn giải, phù hợp khi cần huấn luyện lặp lại qua 5 fold $\times$ 2 máy quang phổ. Huấn luyện được tổ chức thành hai giai đoạn tuần tự: giai đoạn huấn luyện trước (pretraining) bằng hàm mất mát Cross-Entropy trên tổng hai vector hướng dẫn, khôi phục trọng số tại epoch có độ chính xác kiểm định tốt nhất trước khi bước vào giai đoạn khuếch tán đầy đủ, đảm bảo giai đoạn hai luôn khởi đầu từ trạng thái biểu diễn tốt nhất thay vì trạng thái ở epoch huấn luyện cuối cùng. Số bước khuếch tán được đặt $T = 100$, phù hợp với không gian nhãn chỉ 9 chiều (số lớp rau củ quả), không cần lịch trình nhiễu dài như dữ liệu ảnh có độ phân giải cao.

2. Dữ liệu

Bộ dữ liệu gồm phổ NIR thu từ hai máy quang phổ FLAMENIR và OCEANFX trên chín loại rau củ quả phổ biến tại Việt Nam, kèm nhãn nồng độ (mg/kg; giá trị -1 nghĩa là không phát hiện) của 19 loại thuốc trừ sâu, được xác



Hình 4. Kiến trúc tổng quan mô hình GuidedDCNet

(45.883) và Xà Lách (35.598). Mất cân bằng này là một trong các lý do bài toán phân loại (Mục 1.4) dùng kiểm định chéo K-Fold phân tầng (Stratified K-Fold) và theo dõi cả Precision/Recall/F1-score theo trung bình không trọng số qua các lớp (macro-average) thay vì chỉ Accuracy.

Bảng 3. Số lượng mẫu không chứa / có chứa từng thuốc trừ sâu

Thuốc trừ sâu	FLAMENIR		OCEANFX	
	Không chứa	Có chứa	Không chứa	Có chứa
Thiamethoxam	212.768	123.037	340.812	39.217
Permethrin	302.954	32.851	322.664	57.365
Metalaxyl	323.305	12.500	348.423	31.606
Azoxystrobin	297.196	38.609	326.817	53.212
Imidacloprid	303.987	31.818	345.626	34.403
Difenoconazole	297.301	38.504	327.098	52.931
Cypermethrin	310.712	25.093	300.724	79.305
Cyhalothrin	307.959	27.846	342.942	37.087
Chlorantraniliprol	314.507	21.298	356.811	23.218
Chlopyrifos Methyl	320.241	15.564	365.428	14.601
Emamectin benzoate	289.579	46.226	306.278	73.751
Chlorothalonil	278.169	57.636	307.331	72.698
Triadimefon	325.091	10.714	369.551	10.478
Cyantraniliprole	313.967	21.838	351.449	28.580
Flutolanil	308.034	27.771	368.685	11.344
Indoxacarb	324.035	11.770	370.043	9.986
Abamectin	310.571	25.234	343.587	36.442
Propamocarb.HCL	325.134	10.671	368.798	11.231
Chlothianidin	292.847	42.958	289.702	90.327

Cả 19 thuốc trừ sâu đều có mẫu dương trên cả hai máy, không thuốc trừ sâu nào bị loại hoàn toàn khỏi bài toán (2) trên bất kỳ máy nào.

Bảng 3 cho thấy mức mất cân bằng lớp nghiêm trọng hơn nhiều so với bài toán phân loại. Trên FLAMENIR, Thiamethoxam là thuốc trừ sâu phổ biến nhất với 123.037 mẫu dương (36,6% tổng số mẫu); trên OCEANFX, Chlothianidin dẫn đầu với 90.327 mẫu dương (23,8%). Hai thuốc trừ sâu có số mẫu dương ít nhất là Propamocarb.HCL (10.671 trên FLAMENIR) và Triadimefon (10.714 trên FLAMENIR, 10.478 trên OCEANFX) – dù mỏng hơn các thuốc phổ biến, số lượng này đã đủ lớn để không còn là mối lo về độ ổn định của Bước 1, minh chứng bằng kết quả thực nghiệm ở Mục 4.

Trong số các mẫu có chứa thuốc trừ sâu, Bảng 4 phân tách tiếp theo MRL của đúng cặp (thực phẩm, thuốc trừ sâu) của từng mẫu (Mục 2.0.1, Phương trình 9) thành số mẫu An toàn (đã phát hiện nhưng dưới MRL) và Vượt ngưỡng (đã phát hiện và trên MRL). Đây là phần khó thực sự của nhãn Vượt ngưỡng – phân biệt An toàn với Vượt ngưỡng trong số các mẫu đã phát hiện; Bước 2 (Mục 3.2.2) huấn luyện trên toàn bộ mẫu chứ không chỉ tập con này (mẫu không phát hiện được gộp thẳng vào An toàn), nhưng phần thông tin ở bảng này mới là ranh giới quyết định mà mô hình thực sự phải học, phần còn lại (không phát hiện $\Rightarrow$ An toàn) gần như hiển nhiên.

Bảng 4. Trong số mẫu có chứa thuốc trừ sâu: số mẫu An toàn (dưới MRL) và Vượt ngưỡng (trên MRL)

Thuốc trừ sâu	FLAMENIR		OCEANFX	
	An toàn	Vượt ngưỡng	An toàn	Vượt ngưỡng
Thiamethoxam	20.830	102.207	7.964	31.253
Permethrin	4.348	28.503	17.135	40.230
Metalaxyl	1.353	11.147	4.035	27.571
Azoxystrobin	23.338	15.271	33.668	19.544
Imidacloprid	13.024	18.794	13.174	21.229
Difenoconazole	4.615	33.889	5.344	47.587
Cypermethrin	3.834	21.259	13.641	65.664
Cyhalothrin	9.285	18.561	11.309	25.778
Chlorantraniliprol	8.946	12.352	10.339	12.879
Chlopyrifos Methyl	1.353	14.211	2.732	11.869
Emamectin benzoate	2.239	43.987	2.068	71.683
Chlorothalonil	23.473	34.163	35.408	37.290
Triadimefon	0	10.714	0	10.478
Cyantraniliprole	7.616	14.222	12.059	16.521
Flutolanil	0	27.771	0	11.344
Indoxacarb	3.117	8.653	2.110	7.876
Abamectin	1.050	24.184	1.037	35.405
Propamocarb.HCL	4.182	6.489	4.158	7.073
Chlothianidin	1.418	41.540	1.189	89.138

các dòng tô vàng: 0 mẫu An toàn trong số mẫu đã phát hiện, trên cả hai máy (mọi mẫu phát hiện được, trên cả FLAMENIR lẫn OCEANFX, đều Vượt ngưỡng) – không đồng nghĩa Bước 2 thiếu dữ liệu để huấn luyện, vì Bước 2 huấn luyện trên toàn bộ mẫu (Mục 3.2.2) và mẫu không phát hiện luôn được gộp vào lớp An toàn, đủ để cân bằng hai lớp cho cả hai thuốc này.

Nhận xét. Bảng 4 cho thấy bức tranh khá cân bằng: trong số mẫu *đã phát hiện*, chỉ còn đúng hai thuốc trừ sâu có phân bố cực đoan, và cả hai đều nhất quán trên *cả hai máy* – Triadimefon và Flutolanil luôn Vượt ngưỡng khi phát hiện (100% trên cả FLAMENIR và OCEANFX). Propamocarb.HCL có đủ mẫu ở cả hai lớp để không cực đoan (60,8%/63,0%). Vì Bước 2 huấn luyện trên toàn bộ mẫu chứ không riêng tập con đã phát hiện, tính cực đoan của Triadimefon/Flutolanil trong Bảng 4 không khiến Bước 2 thiếu dữ liệu huấn luyện cho hai thuốc này – chỉ phản ánh rằng, một khi đã phát hiện được hai thuốc này, hầu như chắc chắn là Vượt ngưỡng.

Toàn bộ 17 thuốc trừ sâu còn lại đều có đủ hai lớp An toàn và Vượt ngưỡng ngay trong tập con đã phát hiện trên cả hai máy, đủ dữ liệu để Bước 2 thực sự học ranh giới quyết định thay vì chỉ ghi nhớ lớp đa số. Ba thuốc có tỉ lệ Vượt ngưỡng cao nhất và khá nhất quán giữa hai máy là Chlothianidin (96,7%/98,7%), Abamectin (95,8%/97,2%) và Emamectin benzoate (95,2%/97,2%). Một vài thuốc cho thấy khác biệt đáng chú ý giữa hai máy – Chlopyrifos Methyl (91,3% trên FLAMENIR so với 81,3% trên OCEANFX) và Difenoconazole (88,0% so với 89,9%) – cũng cố nhận định đã nêu ở trên rằng khác biệt giữa hai máy chủ yếu đến từ đợt lấy mẫu thực tế (dãi nồng độ được khảo sát) chứ không phải đặc tính riêng của thiết bị đo.

2.2. *Thực quan hóa dữ liệu*

Hình 5 cho thấy các loại rau củ quả có hình dạng phổ NIR khá tương đồng trên cùng một máy (cùng vị trí đỉnh hấp thụ) nhưng khác nhau rõ rệt về cường độ tuyệt đối – ở FLAMENIR, Dưa Leo và Cải Bẹ Xanh cho cường độ cao nhất còn Khổ Qua thấp nhất; đây là cơ sở để mô hình phân biệt được loại rau củ quả từ phổ thô. Phổ từ OCEANFX (Hình 5b) có độ phân giải bước sóng cao hơn nhiều (2.136 so với 128 điểm) và bộc lộ rõ hai đỉnh hấp thụ chính, với Dưa Leo cho cường độ cao nhất tại đỉnh chính và Cà Chua thấp nhất, cùng dải độ lệch chuẩn rộng ở vùng bước sóng giữa, phản ánh mức biến thiên tín hiệu cao hơn giữa các cá thể mẫu trong vùng này.

Hình 6 cho thấy tỉ lệ nhiễm phân bố không đồng đều giữa các loại rau củ quả và giữa hai máy. Trên FLAMENIR, ô có tỉ lệ nhiễm cao nhất toàn bảng là Thiamethoxam tại Cải Bẹ Xanh (46,6%); Thiamethoxam vượt trên 30% ở cả 9/9 loại rau củ quả, nhất quán với việc là thuốc trừ sâu phổ biến nhất trên máy này (Bảng 3). Trên OCEANFX, Chlothianidin dẫn đầu cả về tổng số mẫu dương lẫn tỉ lệ nhiễm theo từng loại, với ô cao nhất toàn bảng là Chlothianidin tại Cà Chua (35,4%) và vượt trên 15% ở 5/9 loại rau củ quả.

Về mức độ đồng nhiễm: trong tổng số 335.805 mẫu FLAMENIR, 29.908 mẫu (8,9%) không phát hiện thuốc trừ sâu nào (mẫu sạch), 110.845 mẫu (33,0%) chỉ chứa đúng một loại, và 195.052 mẫu (58,1%) đồng thời chứa từ hai loại trở lên – trong đó 23.216 mẫu chứa cùng lúc từ bốn loại trở lên. Ở OCEANFX, trong tổng số 380.029 mẫu, 33.195 mẫu (8,7%) là mẫu sạch, 97.005 mẫu (25,5%) chứa đúng một loại, và 249.829 mẫu (65,7%) đồng thời chứa từ hai

loại trở lên – trong đó 35.948 mẫu chứa từ bốn loại trở lên. Đồng nhiễm từ hai loại trở lên là trường hợp *phổ biến nhất* trên cả hai máy, vượt xa cả mẫu sạch lẫn mẫu chỉ chứa một loại – một khác biệt cần lưu ý khi so sánh hiệu năng phát hiện giữa hai máy ở Mục 4. Đồng nhiễm nhiều thuốc trừ sâu cũng là một trong những lý do khiến việc tách bài toán phát hiện thành 19 mô hình nhị phân độc lập (Mục 1.3) phù hợp hơn một bộ phân loại đa nhãn đơn lẻ giả định các nhãn độc lập tuyệt đối.

Hình 7 tách Bảng 4 theo từng loại thực phẩm và cho thấy một hiện tượng quan trọng bị che khuất khi chỉ nhìn số liệu gộp theo máy: phần lớn các cặp (thuốc trừ sâu, loại rau củ quả) gần như *tất định* chứ không hề ”cân bằng” – 115/171 cặp (67,3%) trên FLAMENIR và 109/170 cặp (64,1%) trên OCEANFX có tỉ lệ Vượt ngưỡng đúng bằng 0% hoặc 100%. Hiện tượng này lặp lại nhất quán giữa hai máy: ví dụ Azoxystrobin luôn 0% (toàn bộ mẫu phát hiện đều An toàn) tại Mồng Tơi, Cải Thiệp, Cải Bẹ Xanh và Đậu Cove – trên *cả hai máy* – nhưng phần lớn Vượt ngưỡng ở các loại còn lại; Chlorantraniliprol tương tự luôn 0% tại Mồng Tơi, Cải Thiệp, Cải Bẹ Xanh trên cả hai máy; Indoxacarb luôn 0% tại Đậu Cove và Cà Rốt trên cả hai máy nhưng 100% ở 7 loại còn lại; Propamocarb.HCL luôn 0% tại Mồng Tơi, Cà Chua, Dưa Leo trên cả hai máy.

Điều này giải thích vì sao tỉ lệ Vượt ngưỡng *gộp theo máy* ở Bảng 4 lại có vẻ ”cân bằng vừa phải” với nhiều thuốc trừ sâu (ví dụ Propamocarb.HCL 60,8%/63,0%, Imidacloprid 59,1%/61,7%) – con số gộp đó thực chất là hỗn hợp của các loại thực phẩm gần như chắc chắn An toàn và các loại gần như chắc chắn Vượt ngưỡng, chứ không phải một ranh giới quyết định mờ nhạt cần suy luận từ phổ. Quan sát này củng cố trực tiếp quyết định đưa loại thực phẩm vào làm đặc trưng đầu vào tường minh cho Bước 1 và Bước 2 (Mục 1.1): với nhiều cặp (thuốc, thực phẩm), chỉ riêng việc biết đúng loại thực phẩm đã gần như quyết định được nhãn An toàn/Vượt ngưỡng, nên phần khó thực sự của bài toán tập trung ở một tập con nhỏ hơn nhiều so với 19 thuốc $\times$ 9 loại thực phẩm đầy đủ.

3. *Thiết lập thực nghiệm*


Tất cả các thí nghiệm được thực hiện trên hệ điều hành Ubuntu 22.04, sử dụng PyTorch 2.9.1 và Python 3.12.11 với CUDA hỗ trợ, chạy trên GPU NVIDIA GeForce RTX 5060 Ti (16 GB VRAM) và được trang bị CPU Intel® Xeon® E5-2696 v3 @ 2.30 GHz (72 luồng, 125 GB RAM).

3.1. *Phân loại rau củ quả*


3.1.1. *Tiền xử lý dữ liệu*

Dữ liệu phổ NIR thường chịu ảnh hưởng của nhiễu, tán xạ và sai lệch đường nền, do đó cần được tiền xử lý trước khi đưa vào mô hình phân loại. Trước hết, dữ liệu được làm sạch nhằm loại bỏ các phổ lỗi và giá trị ngoại lai. Tiếp theo, kỹ thuật Savitzky–Golay được sử dụng để giảm nhiễu và hiệu chỉnh đường nền giúp làm nổi bật các đặc trưng quan trọng.

Để hạn chế ảnh hưởng của tán xạ ánh sáng, phương pháp



(a) Máy FLAMENIR



(b) Máy OCEANFX

Hình 5. Phổ NIR trung bình (đường liền) và dải độ lệch chuẩn (vùng tô) theo loại rau củ quả

chuẩn hóa biến số chuẩn (Standard Normal Variate – SNV) được sử dụng. Sau đó, dữ liệu được chuẩn hóa về cùng thang đo nhằm đảm bảo quá trình học ổn định. Cuối cùng, dữ liệu được chia thành các tập huấn luyện và kiểm tra phục vụ cho bài toán phân loại.

3.1.2. Chi tiết huấn luyện

Quá trình huấn luyện mô hình phân loại phổ NIR được triển khai bằng PyTorch, với chiến lược kiểm định chéo K-Fold nhằm đánh giá độ ổn định và khả năng tổng quát hóa của mô hình. Cụ thể, dữ liệu được chia thành 5 fold theo phương pháp K-Fold phân tầng (Stratified K-Fold), đảm bảo phân bố nhân giữa các tập huấn luyện và kiểm tra được giữ cân bằng.


Trước mỗi fold, dữ liệu huấn luyện được sử dụng để ước lượng tham số chuẩn hóa và ánh xạ nhẵn, sau đó áp dụng thống nhất cho cả tập huấn luyện và tập kiểm tra nhằm tránh rò rỉ thông tin. Trong mỗi fold, dữ liệu được lấy mẫu và gom thành lô (batch) kích thước 512, giúp tăng hiệu quả huấn luyện trên GPU. Riêng SMART-NIR và GuidedDCNet trên máy OCEANFX, phổ 2.136 điểm được gộp trung bình theo nhóm 8 điểm liên tiếp còn 264 điểm trước khi đưa vào mô hình – độ phân giải đầy đủ khiến chi phí tính toán của cơ chế tự chú ý (self-attention) và bộ mã hóa ResNet1D tăng mạnh, trong khi 264 điểm vẫn giữ nguyên các đỉnh hấp thụ chính quan sát được ở Hình 5. XGBoost và LightGBM không cần bước này, vì cây quyết định vốn không nhạy với số chiều đầu vào theo cách đó.

Mô hình SMART-NIR được khởi tạo với các tham số chính bao gồm: (1) Chiều dài tín hiệu đầu vào bằng độ dài phổ sau tiền xử lý; (2) Số kênh đầu ra cho mỗi nhánh đa kernel là 64; (3) Kích thước không gian đặc trưng là 128; (4) Số tầng Transformer là 3 với 4 đầu tự chú ý mỗi tầng; (5) Bộ phân loại cuối sử dụng KAN với số lớp đầu ra tương ứng với số nhãn trong tập dữ liệu.


Hàm mất mát được sử dụng là Focal Loss ($\gamma = 2$), với

trọng số α của mỗi lớp tỉ lệ nghịch với tần suất lớp đó trong fold huấn luyện. So với hàm entropy chéo (Cross-Entropy) thông thường, Focal Loss giảm đóng góp gradient của các mẫu dễ (thường thuộc lớp đa số) và tập trung hơn vào lớp thiếu số, phù hợp với đặc điểm mất cân bằng dữ liệu đã nêu ở Mục 2.1. Quá trình tối ưu tham số được thực hiện bằng trình tối ưu AdamW (suy giảm trọng số/weight decay 10^{-4}) nhằm hạn chế quá khớp (overfitting). Tốc độ học được điều chỉnh theo lịch trình gồm hai giai đoạn: khởi động (warmup) tuyến tính trong 10 lượt huấn luyện đầu (epoch, 5% tổng số lượt), tăng dần từ 10^{-4} lên 10^{-3} , sau đó giảm dần về gần 0 theo lịch suy giảm dạng cos (Cosine Annealing) trong các lượt còn lại. Trong mỗi lượt huấn luyện, mô hình được huấn luyện trên tập huấn luyện với cơ chế lan truyền ngược, sau đó được đánh giá trên tập đánh giá ở chế độ suy luận theo các chỉ trình bày ở Mục 4.1. Cơ chế dừng sớm (early stopping) được áp dụng dựa trên độ chính xác trên tập đánh giá, với ngưỡng kiên nhẫn là 10 epoch: mô hình đạt độ chính xác kiểm tra cao nhất sẽ được lưu lại, và quá trình huấn luyện dừng sớm nếu không có cải thiện trong nhiều epoch liên tiếp.

GuidedDCNet (Mục 1.4.4) được huấn luyện theo hai giai đoạn tuần tự, trên cùng cách chia K-Fold nêu trên để đảm bảo so sánh công bằng với SMART-NIR. Giai đoạn 1 (huấn luyện trước) chạy cố định 25 epoch, tối ưu hàm mất mát Cross-Entropy trên tổng logits của MCGM và một đầu phân loại tạm thời gắn vào bộ mã hóa dữ liệu (bị loại bỏ sau giai đoạn này), dùng Adam với tốc độ học 5×10^{-4} ; trọng số tại epoch đạt độ chính xác kiểm định cao nhất được khôi phục trước khi bước sang giai đoạn 2 thay vì dùng trọng số ở epoch cuối cùng. Giai đoạn 2 (huấn luyện khuếch tán đầy đủ) chạy cố định 200 epoch, không dừng sớm, phù hợp với đặc điểm hàm mất mát khuếch tán vốn dao động mạnh giữa các epoch (Phương trình 8 với t được lấy mẫu ngẫu nhiên mỗi batch) nên tiêu chí dừng sớm dựa trên hàm mất mát thô để kích hoạt nhằm. Tham số được tối ưu bằng Adam với hai



(a) Máy FLAMENIR



(b) Máy OCEANFX

Hình 6. Tỷ lệ (%), một chữ số thập phân) mẫu có chứa từng thuốc trừ sâu theo loại rau củ quả, dùng chung thang màu giữa hai máy để so sánh

nhóm tốc độ học riêng: 5×10^{-4} cho MCGM và bộ mã hóa dữ liệu, 10^{-3} cho UNet có điều kiện, cùng lịch suy giảm Cosine Annealing trên toàn bộ 200 epoch. Ở mỗi epoch, mô hình được đánh giá bằng một lượt khuếch tán ngược đầy đủ $T = 100$ bước (Mục 1.4.4); checkpoint tại epoch đạt độ chính xác kiểm định cao nhất được lưu lại.

XGBoost và LightGBM (Mục 1.3, 1.4) được huấn luyện trên cùng cách chia K-Fold phân tầng nêu trên, nhưng trực tiếp trên phổ NIR sau Savitzky–Golay và SNV, không qua thêm bước chuẩn hóa nào khác: cây quyết định bất biến với các phép biến đổi affine theo từng cột (mỗi nhất cắt chỉ so sánh giá trị trong cùng một đặc trưng), nên không cần chuẩn hóa như đầu vào của SMART-NIR/GuidedDCNet. Cả hai dùng hàm mục tiêu entropy chéo đa lớp, tối đa 300 cây, độ sâu tối đa 6, tốc độ học 0,1, cùng cơ chế dừng sớm sau 20 vòng lặp không cải thiện log-loss trên tập kiểm tra.


3.2. Đánh giá an toàn thuốc trừ sâu

3.2.1. Tiền xử lý dữ liệu


Tương tự với quy trình tiền xử lý ở bài toán phân loại, dữ liệu phổ NIR ban đầu được làm sạch nhằm loại bỏ các phổ

lỗi và giá trị ngoại lai, sau đó áp dụng Savitzky–Golay và SNV để làm nổi bật các đặc trưng quan trọng và hạn chế ảnh hưởng của tán xạ ánh sáng.

Toàn bộ dữ liệu (kể cả mất cân bằng) được giữ nguyên cho cả hai bước, không loại bớt mẫu nào khỏi tập huấn luyện; mất cân bằng nhân được xử lý trực tiếp trong quá trình huấn luyện (trọng số bù đắp mất cân bằng lớp cho XGBoost/LightGBM, lấy mẫu lại lớp dương theo lô cho SMART-NIR, Mục 3.2.2). Nhân Bước 1 ánh xạ trực tiếp từ giá trị đo (-1 hay khác -1); nhân Bước 2 so sánh nồng độ thực đo với MRL theo Phương trình 9, trong đó mẫu không phát hiện (-1) luôn được gán An toàn cùng với mẫu phát hiện nhưng dưới MRL, tra đúng ngưỡng MRL của cặp (thực phẩm, thuốc trừ sâu) tương ứng từng mẫu (Mục 2.0.1). Với cả hai bước, loại thực phẩm của mẫu (nhân thật khi huấn luyện) được mã hóa one-hot (9 chiều) và nối thêm vào đặc trưng phổ trước khi đưa vào mô hình, vì ngưỡng MRL dùng để gán nhãn phụ thuộc trực tiếp vào loại thực phẩm. Cuối cùng, dữ liệu được chia thành các tập huấn luyện và kiểm tra phục vụ cho từng bước.



(a) Máy FLAMENIR



(b) Máy OCEANFX

Hình 7. Tỷ lệ (%), làm tròn) Vượt ngưỡng trong số mẫu đã phát hiện, theo từng cặp (thuốc trừ sâu, loại rau củ quả) – phân tách theo loại thực phẩm của Bảng 4. Ô “–” (Chlopyrifos Methyl tại Xà Lách, OCEANFX) không có mẫu phát hiện nào để tính tỷ lệ.

3.2.2. Chi tiết huấn luyện

Một chiến lược huấn luyện hai bước theo tầng (cascade) được sử dụng nhằm xử lý hiệu quả bài toán đánh giá an toàn thuốc trừ sâu với nhiều thuốc trừ sâu khác nhau. Cách tiếp cận này cho phép tách biệt rõ ràng giữa bài toán phát hiện sự hiện diện của thuốc trừ sâu và bài toán phân loại mức độ an toàn, từ đó nâng cao độ ổn định và độ chính xác của toàn hệ thống. Cả hai bước huấn luyện độc lập cho từng loại trong 19 thuốc trừ sâu khảo sát, và ba kiến trúc của Mô-đun Phân loại (XGBoost, LightGBM, SMART-NIR; Mục 1.2) được cài đặt và đánh giá cho mỗi bước.

Bước 1 – Phát hiện: Mỗi thuốc trừ sâu được xem như một bài toán phân loại nhị phân độc lập, trong đó mục tiêu là xác định liệu thuốc trừ sâu đó có xuất hiện trong mẫu hay không. Nhãn được xây dựng bằng cách ánh xạ giá trị đo: các mẫu có giá trị khác -1 được gán nhãn 1 (có thuốc trừ sâu), trong khi các mẫu có giá trị -1 được gán nhãn 0 (không có thuốc trừ sâu, kết luận cuối cùng An toàn ngay ở bước này). Quá trình huấn luyện sử dụng kiểm định chéo K-Fold phân tầng (5 fold) để đảm bảo phân bố nhãn cân bằng giữa các tập.

Với XGBoost/LightGBM (Mục 1.3, 1.4), mô hình được huấn luyện với hàm mục tiêu binary logistic, kết hợp cơ chế dừng sớm dựa trên log-loss của tập kiểm tra. Trọng số bù đắp mất cân bằng lớp được đặt bằng tỷ lệ số mẫu âm/dương của fold huấn luyện để bù đắp mất cân bằng nhãn mà không cần loại bỏ dữ liệu. Độ phức tạp cây (số cây, độ sâu tối đa, tốc độ học) được điều chỉnh theo số mẫu dương của từng thuốc trừ sâu – thuốc có ít mẫu dương hơn dùng cây nông và ít cây hơn để giảm nguy cơ quá khớp. Với SMART-NIR, mất cân bằng nhãn – thường nặng hơn nhiều so với bài toán phân loại thực phẩm, có thuốc trừ sâu chỉ chiếm dưới 3% mẫu dương (Bảng 3) – được xử lý bằng lấy mẫu lại (oversampling) lớp dương ngay trong mỗi lô huấn luyện: 25% mỗi lô luôn là mẫu dương (lấy có hoàn lại), phần còn lại lấy ngẫu nhiên từ lớp âm, thay vì gán trọng số như XGBoost/LightGBM hay dùng Focal Loss. Thử nghiệm thực tế cho thấy với thuốc hiếm, huấn luyện theo lô hoàn toàn ngẫu nhiên khiến phần lớn lô không có mẫu dương nào, mô hình dễ mắc kẹt ở lời giải tầm thường (luôn đoán không có) trong nhiều epoch đầu; lấy mẫu lại đảm bảo mọi lô đều mang tín hiệu của lớp thiểu số. Hàm mất mát là entropy chéo thông

thường (không cần trọng số riêng, vì việc lấy mẫu lại đã cân bằng lớp ở cấp độ lô). SMART-NIR dùng AdamW (tốc độ học đỉnh 2×10^{-3} , suy giảm trọng số 10^{-4}) với lịch OneCycle (khởi động 10% số epoch đầu, sau đó suy giảm dần), lô kích thước 2.048, tối đa 50 epoch, dừng sớm theo PR-AUC trên tập đánh giá (không sớm hơn epoch thứ 10, để tránh dừng nhầm trong pha tốc độ học còn cao) với ngưỡng kiên nhẫn 8 epoch.

Vì cơ chế bù đắp mất cân bằng lớp (trọng số cho XGBoost/LightGBM, lấy mẫu lại cho SMART-NIR) làm lệch xác suất đầu ra của mô hình khỏi xác suất thực, một bước hiệu chỉnh Platt scaling (hồi quy logistic một chiều) được khớp và áp dụng lại cho tập kiểm tra để tránh rò rỉ thông tin. Với XGBoost/LightGBM, Platt scaling được khớp trực tiếp trên dự đoán của toàn bộ tập huấn luyện. Với SMART-NIR, một phần nhỏ (15%) của tập huấn luyện được tách riêng trước khi bắt đầu huấn luyện, không tham gia cập nhật trọng số mạng, chỉ dùng để khớp Platt scaling và chọn ngưỡng (bên dưới): vì mạng nơ-ron dễ khớp gần như hoàn hảo chính các mẫu đã thấy (train loss tiệm cận 0), hiệu chỉnh trên chính các mẫu đó cho ra ngưỡng quá khắt khe khi áp dụng lại cho mẫu chưa thấy, trong khi XGBoost/LightGBM không gặp vấn đề tương tự ở cùng mức độ.

Thay vì cố định ngưỡng phân loại ở 0,5, ngưỡng quyết định được chọn tự động bằng cách quét toàn bộ đường cong Precision-Recall (trên xác suất đã hiệu chỉnh của cùng tập dữ liệu dùng để khớp Platt scaling ở trên – toàn bộ tập huấn luyện với XGBoost/LightGBM, phân tách riêng 15% với SMART-NIR – cùng lý do tránh rò rỉ) và chọn ngưỡng cho Precision cao nhất trong số các ngưỡng đạt Recall lớp dương $\geq 0,9$; nếu không ngưỡng nào đạt được mục tiêu này, ngưỡng cho Recall cao nhất được dùng thay thế. Lựa chọn này phản ánh đặc thù bài toán an toàn thực phẩm, nơi bỏ sót một mẫu thực sự có thuốc trừ sâu (false negative) gây hậu quả nghiêm trọng hơn nhiều so với một cảnh báo giả (false positive) cần kiểm tra lại. Ngưỡng được lưu lại cùng mô hình và bộ hiệu chỉnh để tái sử dụng khi suy luận.

Sau khi huấn luyện, mô hình được đánh giá theo các tiêu chí phân loại ở Mục 4.1, cùng với PR-AUC và Brier score trước/sau hiệu chỉnh để theo dõi thêm chất lượng xác suất dự đoán; do ngưỡng được tối ưu theo Recall thay vì mặc định 0,5, PR-AUC (không phụ thuộc ngưỡng) là chỉ số đáng tin cậy hơn Accuracy/F1 khi so sánh hiệu năng phát hiện giữa các thuốc trừ sâu.

Ở suy luận, Bước 1 đóng vai trò như một bộ lọc (screening stage): chỉ khi Bước 1 báo có phát hiện thì dự đoán của Bước 2 mới thực sự được sử dụng cho mẫu đó, còn lại kết luận An toàn được quyết định ngay từ Bước 1.

Bước 2 – Phân loại mức độ: Khác với một cascade huấn luyện thuần túy (chỉ dùng tập con Bước 1 xác định có phát hiện), Bước 2 huấn luyện trên *toàn bộ* mẫu, cùng cỡ dữ liệu với Bước 1. Với mỗi thuốc trừ sâu, ba mô hình độc lập (XGBoost, LightGBM, SMART-NIR) được huấn luyện nhằm phân loại nhị phân An toàn/Vượt ngưỡng, tái sử dụng gần như nguyên vẹn cấu hình huấn luyện của Bước 1 (cùng

hàm mục tiêu, cùng cơ chế cân bằng lớp, cùng bước hiệu chỉnh Platt scaling và chọn ngưỡng theo Recall $\geq 0,9$ mô tả ở trên) – bỏ sót một mẫu thực sự vượt ngưỡng MRL cũng nguy hiểm như bỏ sót một mẫu có thuốc trừ sâu ở Bước 1, nên áp dụng cùng triết lý ưu tiên Recall.

Khác biệt so với Bước 1 nằm ở nguồn nhãn: nhãn Bước 2 so sánh nồng độ thực đo với MRL của đúng cặp (thực phẩm, thuốc trừ sâu) của mẫu đó (Phương trình 9) thay vì chỉ kiểm tra -1 hay khác -1 , nên cùng một mức nồng độ tuyệt đối có thể là An toàn với thực phẩm này nhưng Vượt ngưỡng với thực phẩm khác; mẫu không phát hiện luôn được gán An toàn, giống mẫu phát hiện nhưng dưới MRL. Vì tập huấn luyện của Bước 2 có cùng quy mô với Bước 1 (không giới hạn ở tập con đã phát hiện, vốn nhỏ hơn nhiều), phần lớn nhãn dương (Vượt ngưỡng) chiếm tỉ lệ nhỏ hơn hẳn so với khi chỉ tính trên mẫu đã phát hiện (Bảng 4); điều kiện dừng huấn luyện (≥ 5 mẫu mỗi lớp cho 5-fold) áp dụng như Bước 1, và không thuốc trừ sâu nào bị bỏ qua ở Bước 2 trên cả hai máy.

Hiệu chỉnh theo prior thực phẩm (Bước 2). Hình 7 cho thấy phần lớn các cặp (thực phẩm, thuốc trừ sâu) gần như tất định trong dữ liệu hiện có – không có mẫu nào nằm gần ranh giới MRL để mô hình học phân biệt từ phổ, nên một mô hình phổ thuần túy dễ khớp theo nhiều thay vì một ranh giới quyết định thực sự tồn tại ở những cặp này. Vì thu thập thêm dữ liệu ở những cặp đó không khả thi trong phạm vi báo cáo này, xác suất dự đoán của Bước 2 (sau hiệu chỉnh Platt scaling) được trộn thêm với một *prior* thực nghiệm theo riêng loại thực phẩm của mẫu, p_f – tỉ lệ Vượt ngưỡng làm mịn Beta(1,1) ước lượng trên chính tập huấn luyện của fold đó (không dùng tập kiểm tra, tránh rò rỉ thông tin):

$$\hat{p} = \alpha_f p_f + (1 - \alpha_f) p_{\text{model}}, \quad \alpha_f = \text{clip}(1 - 4 p_f (1 - p_f), 0, 1) \quad (10)$$

với p_{model} là xác suất mô hình đã hiệu chỉnh Platt scaling. Trọng số α_f được suy trực tiếp từ phương sai Bernoulli của p_f : bằng 1 khi loại thực phẩm đó gần như tất định (p_f gần 0 hoặc 1, mọi mẫu lịch sử đều đồng thuận), khi đó $\hat{p}$ tin hoàn toàn vào p_f thay vì để mô hình phổ tự suy luận trên dữ liệu vốn không hỗ trợ; bằng 0 khi p_f gần 0,5 (loại thực phẩm đó thực sự cân bằng), khi đó $\hat{p}$ tin hoàn toàn vào mô hình phổ, đúng nơi dữ liệu có tín hiệu để học. Đây là cách tận dụng tối đa thông tin đã có mà không cần thêm mẫu mới: mô hình chỉ tự tin dựa vào phổ ở những cặp thực sự có bằng chứng, còn lại quay về câu trả lời an toàn nhất mà dữ liệu lịch sử thể hiện. Ngưỡng quyết định theo Recall (Phương trình ở trên) được quét lại trên chính $\hat{p}$ của tập huấn luyện để nhất quán với xác suất cuối cùng dùng ở suy luận.

4. Kết quả

4.1. Tiêu chí đánh giá

Cả ba bài toán con – phân loại thực phẩm, Bước 1 (Phát hiện) và Bước 2 (Phân loại mức độ) – đều là bài toán phân loại, nên dùng chung một bộ chỉ số đánh giá.

Chỉ số phân loại. Gọi C là số lớp; với mỗi lớp c , gọi TP_c, FP_c, FN_c lần lượt là số mẫu dương thật, dương giả

và âm giả của lớp đó trên tập kiểm tra. Accuracy là tỉ lệ mẫu dự đoán đúng trên tổng số mẫu, trong khi Precision, Recall và F1-score được tính theo trung bình không trọng số qua các lớp (macro-average) để không bị chi phối bởi lớp đa số, phù hợp với đặc điểm mất cân bằng dữ liệu đã nêu ở Mục 2.1:

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c}, \quad \text{Recall}_c = \frac{TP_c}{TP_c + FN_c},$$

$$F1_c = \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \quad (11)$$

$$\text{Precision} = \frac{1}{C} \sum_{c=1}^C \text{Precision}_c,$$

$$\text{Recall} = \frac{1}{C} \sum_{c=1}^C \text{Recall}_c,$$

$$F1 = \frac{1}{C} \sum_{c=1}^C F1_c \quad (12)$$

Với Bước 1 và Bước 2 (đều nhị phân), $C = 2$.

Chỉ số bổ sung cho Bước 1 và Bước 2. Vì cả hai bước đều huấn luyện trên toàn bộ mẫu và đều mất cân bằng lớp – lớp Vượt ngưỡng vốn đã là thiểu số ngay trong tập con đã phát hiện với một số thuốc trừ sâu (Bảng 4), lại càng nhỏ hơn khi tính trên toàn bộ mẫu của Bước 2 (Mục 3.2.2) – hai chỉ số bổ sung được theo dõi cùng Accuracy/Precision/Recall/F1: PR-AUC (diện tích dưới đường cong Precision-Recall khi quét ngưỡng phân loại), ít nhạy với mất cân bằng lớp hơn ROC-AUC; và Brier score – sai số bình phương trung bình giữa xác suất dự đoán $\hat{p}_i$ và nhãn thực $l_i \in \{0, 1\}$, $\text{Brier} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - l_i)^2$ – đo chất lượng hiệu chỉnh xác suất, được báo cáo trước và sau bước Platt scaling để định lượng mức cải thiện. Riêng Bước 2, Brier score còn được báo cáo thêm sau bước trộn với prior thực phẩm (Mục 3.2.2, Phương trình 10) để định lượng mức cải thiện của kỹ thuật này so với chỉ hiệu chỉnh Platt scaling.

4.2. Máy FLAMENIR

4.2.1. Phân loại rau củ quả

Bảng 5. Phân loại rau củ quả trên máy FLAMENIR (trung bình 5 fold, %)

Phương pháp	Accuracy	Precision	Recall	F1
XGBoost	80,55	79,06	79,21	78,90
LightGBM	82,50	81,15	81,24	81,03
SMART-NIR	89,64	88,86	88,89	88,86
GuidedDCNet	91,96	91,36	91,34	91,34

Bảng 5 cho thấy hai kiến trúc mạng nơ-ron sâu vượt trội rõ rệt so với hai mô hình cây trên bài toán phân loại 9 lớp: GuidedDCNet đạt Accuracy cao nhất (91,96%), theo sau là SMART-NIR (89,64%), cách biệt khoảng 9–11 điểm phần trăm so với LightGBM (82,50%) và XGBoost (80,55%) –

phương pháp yếu nhất. Precision, Recall và F1 (macro-average) bám sát Accuracy ở cả bốn phương pháp, cho thấy không có lớp rau củ quả nào bị bỏ sót một cách bất thường dù phân bố mẫu giữa các lớp không hoàn toàn cân bằng (Bảng 2).

4.2.2. Đánh giá an toàn thuốc trừ sâu

Ở Bước 1 (Bảng 6), SMART-NIR vượt trội rõ rệt so với XGBoost và LightGBM trên mọi chỉ số, đặc biệt PR-AUC (88,83% so với khoảng 54–55%) – phù hợp quan sát ở Mục 2.1 rằng cây quyết định khó tách được tín hiệu thuốc trừ sâu yếu khỏi phổ NIR nếu chỉ dựa vào các nhất cốt theo từng đặc trưng đơn lẻ. Recall macro của cả ba phương pháp đều trên 80%, phản ánh đúng chủ đích chọn ngưỡng ưu tiên $\text{Recall} \geq 90\%$ cho riêng lớp dương (Mục 3.2.2) – Accuracy và F1 (macro, chịu ảnh hưởng của cả hai lớp) vì vậy thấp hơn PR-AUC (không phụ thuộc ngưỡng) một cách có chủ đích, không phải dấu hiệu mô hình kém.

Ở Bước 2 (Bảng 7), thứ hạng giữa các phương pháp giữ nguyên như Bước 1: SMART-NIR dẫn đầu (PR-AUC 81,97%), XGBoost và LightGBM thấp hơn nhiều và gần như ngang nhau (44,93% và 45,40%). Đúng như dự đoán ở Mục 3.2.2, bài toán Bước 2 khó hơn Bước 1 (nhân phụ thuộc thêm vào MRL của từng loại thực phẩm), nên PR-AUC nhìn chung thấp hơn bằng tương ứng của Bước 1 với cùng phương pháp. Riêng Brier score sau bước trộn prior thực phẩm (Phương trình 10) lại *cao hơn* (kém hơn) Brier score chỉ sau Platt scaling ở cả XGBoost (5,30% so với 4,75%) lẫn SMART-NIR (3,74% so với 2,04%) khi gộp trung bình 19 thuốc – ngược với kỳ vọng ban đầu của kỹ thuật này. Nguyên nhân nhiều khả năng là dù phần lớn cặp (thực phẩm, thuốc trừ sâu) hưởng lợi từ việc trộn với prior gần như tất định (Hình 7), một số cặp khác có prior ước lượng trên fold huấn luyện lệch so với tập kiểm tra, kéo trung bình chung lên; đây là một phát hiện thực nghiệm cần diễn giải thận trọng hơn giả định ban đầu, không loại trừ khả năng kỹ thuật này vẫn có ích cho việc chọn ngưỡng theo Recall dù không cải thiện Brier score trung bình.

Đánh giá trên tập kiểm tra độc lập. Ngoài kiểm định chéo K-Fold, Bước 1 còn được đánh giá thêm trên 100 mẫu mỗi máy tách riêng trước khi huấn luyện (không tham gia bất kỳ fold nào). Trên FLAMENIR, Accuracy/Recall/PR-AUC (gộp dự đoán của 5 mô hình theo fold bằng trung bình xác suất) lần lượt là 78,89%/77,42%/52,16% với XGBoost, 78,95%/78,17%/51,36% với LightGBM và 93,53%/92,72%/90,23% với SMART-NIR – gần như trùng khớp với kết quả kiểm định chéo ở Bảng 6 (chênh lệch dưới 3 điểm phần trăm ở mọi chỉ số), cho thấy các con số kiểm định chéo phản ánh khá tốt hiệu năng trên mẫu chưa từng thấy trong huấn luyện.

4.3. Máy OCEANFX

4.3.1. Phân loại rau củ quả

Bảng 8 cho thứ hạng giữa bốn phương pháp giống hệt FLAMENIR (Bảng 5) – GuidedDCNet và SMART-NIR vượt

Bảng 6. Bước 1 – Phát hiện, máy FLAMENIR (trung bình 5 fold theo từng thuốc trừ sâu, %)

Thuốc trừ sâu	XGBoost					LightGBM					SMART-NIR				
	Acc.	Prec.	Rec.	F1	PR-AUC	Acc.	Prec.	Rec.	F1	PR-AUC	Acc.	Prec.	Rec.	F1	PR-AUC
Thiamethoxam	71,78	73,69	75,15	71,62	74,39	71,71	73,63	75,09	71,56	74,33	91,69	90,88	91,36	91,11	96,14
Permethrin	74,61	61,46	78,13	61,42	57,95	74,66	61,46	78,10	61,45	58,03	91,86	77,01	91,16	81,89	87,73
Metalaxyl	90,13	61,00	81,16	64,85	44,91	90,55	61,33	80,86	65,29	45,33	95,05	70,97	92,56	77,45	82,59
Azoxystrobin	83,07	68,43	83,95	71,63	67,53	83,64	68,84	84,08	72,19	68,06	98,29	96,85	94,63	95,70	97,66
Imidacloprid	78,59	63,09	80,51	64,59	52,84	79,18	63,37	80,71	65,10	53,63	96,70	88,66	93,77	90,99	93,45
Difenoconazole	83,80	68,90	84,03	72,29	67,88	84,13	69,19	84,22	72,65	68,27	98,30	96,63	94,86	95,72	97,52
Cypermethrin	85,30	64,84	83,57	68,42	66,12	85,21	64,78	83,57	68,33	66,30	96,55	85,25	93,57	88,86	91,57
Cyhalothrin	87,14	67,62	83,99	71,73	66,94	87,22	67,73	84,13	71,87	67,13	96,67	87,07	93,52	89,96	92,75
Chlorantraniliprol	80,07	59,66	79,25	60,77	37,04	80,77	59,88	79,19	61,27	37,70	88,97	67,39	89,51	72,36	75,59
Chlopyrifos Methyl	87,73	61,36	82,17	64,86	46,53	88,21	61,73	82,29	65,42	46,91	96,28	77,88	93,54	83,67	85,91
Emamectin benzoate	73,95	64,63	78,19	64,88	59,65	74,21	64,73	78,26	65,09	59,78	94,61	87,00	92,53	89,46	92,61
Chlorothalonil	67,73	63,92	74,10	61,95	58,50	68,28	64,10	74,34	62,39	58,98	90,30	81,86	90,19	85,02	90,14
Triadimefon	92,19	61,84	81,76	66,22	43,84	92,25	61,80	81,22	66,13	43,40	97,09	76,18	93,91	82,52	87,01
Cyantraniliprole	85,20	63,07	82,59	66,35	55,00	85,89	63,57	82,81	67,09	55,64	98,45	93,03	94,52	93,75	94,85
Flutolanil	73,12	59,11	76,02	58,02	40,68	73,85	59,31	76,25	58,54	41,39	90,47	72,52	89,96	77,69	81,66
Indoxacarb	95,83	71,74	85,99	76,85	64,80	95,98	72,30	85,94	77,29	65,31	96,86	76,38	93,85	82,64	86,21
Abamectin	74,90	58,91	76,61	58,31	39,81	74,65	58,81	76,42	58,10	39,86	90,67	71,65	90,49	77,01	80,96
Propamocarb.HCL	88,67	58,15	78,97	60,82	30,00	89,25	58,43	78,62	61,32	29,82	95,36	69,75	92,72	76,38	79,78
Chlothianidin	75,56	64,68	79,15	65,46	61,58	75,70	64,74	79,19	65,57	61,69	95,75	88,98	93,36	90,99	93,68
Trung bình	81,55	64,00	80,28	65,84	54,53	81,86	64,20	80,28	66,14	54,82	94,73	81,89	92,63	85,43	88,83

Bảng 7. Bước 2 – Phân loại mức độ, máy FLAMENIR (trung bình 5 fold theo từng thuốc trừ sâu, %)

Thuốc trừ sâu	XGBoost					LightGBM					SMART-NIR				
	Acc.	Prec.	Rec.	F1	PR-AUC	Acc.	Prec.	Rec.	F1	PR-AUC	Acc.	Prec.	Rec.	F1	PR-AUC
Thiamethoxam	73,09	72,91	77,05	71,97	70,13	73,08	72,91	77,04	71,96	70,14	91,82	89,87	91,28	90,52	93,95
Permethrin	70,06	58,81	75,95	56,41	55,70	70,16	58,85	76,06	56,50	55,87	90,44	72,88	90,42	78,08	81,57
Metalaxyl	74,63	53,96	74,31	50,63	30,15	75,58	54,03	74,04	51,09	30,63	79,91	56,48	84,87	55,83	72,18
Azoxystrobin	89,62	63,77	86,97	68,36	54,82	90,28	64,38	86,75	69,18	56,18	98,03	86,23	94,28	89,80	88,36
Imidacloprid	66,66	55,84	75,68	50,61	33,40	71,86	56,80	77,98	53,96	34,08	96,21	80,17	93,41	85,35	83,26
Difenoconazole	83,17	66,93	83,87	70,14	64,15	83,31	67,05	84,02	70,31	64,46	98,02	94,66	94,41	94,53	93,86
Cypermethrin	84,74	62,65	83,08	65,76	60,72	85,37	63,07	83,24	66,41	60,94	96,50	82,93	93,43	87,29	86,43
Cyhalothrin	88,48	63,80	82,52	67,86	44,86	88,83	64,16	82,67	68,33	45,32	95,50	77,67	92,79	83,23	82,54
Chlorantraniliprol	88,75	60,18	82,95	63,62	37,46	89,81	60,97	82,78	64,83	38,93	93,18	66,85	91,22	72,81	72,27
Chlopyrifos Methyl	66,23	53,97	72,55	47,73	28,78	67,58	54,13	72,97	48,49	28,79	88,32	63,78	89,18	67,57	74,06
Emamectin benzoate	63,96	60,72	73,35	56,50	56,10	64,32	60,79	73,46	56,76	56,22	93,19	83,34	91,66	86,76	88,99
Chlorothalonil	69,19	59,73	74,91	57,47	35,89	70,01	59,95	75,22	58,06	36,23	87,84	71,94	88,89	76,49	77,70
Triadimefon	83,80	56,25	79,60	56,89	26,92	84,04	56,27	79,31	57,00	26,32	87,51	59,36	88,74	62,32	75,22
Cyantraniliprole	85,53	59,08	81,05	61,40	36,34	86,74	59,76	81,25	62,58	36,97	97,90	84,61	94,06	88,67	84,75
Flutolanil	70,30	58,37	75,02	56,04	37,05	71,27	58,63	75,46	56,73	37,50	89,57	71,45	89,28	76,39	76,99
Indoxacarb	97,20	73,27	86,06	78,15	62,99	97,39	74,46	86,04	79,04	64,37	97,93	78,13	94,18	84,15	84,65
Abamectin	69,62	57,27	74,64	54,21	37,29	70,74	57,43	74,76	54,87	37,80	90,29	70,51	89,90	75,79	78,00
Propamocarb.HCL	93,00	57,75	78,41	61,10	22,54	94,03	58,80	77,76	62,58	23,39	88,96	57,24	89,52	59,53	72,38
Chlothianidin	47,95	57,56	66,40	44,34	58,31	47,90	57,58	66,43	44,31	58,46	94,46	85,34	92,50	88,42	90,18
Trung bình	77,16	60,67	78,12	59,96	44,93	78,02	61,05	78,28	60,68	45,40	92,40	75,44	91,26	79,13	81,97

Bảng 8. Phân loại rau củ quả trên máy OCEANFX (trung bình 5 fold, %)

Phương pháp	Accuracy	Precision	Recall	F1
XGBoost	88,33	88,10	88,10	88,05
LightGBM	90,11	89,94	89,91	89,90
SMART-NIR	96,79	96,70	96,75	96,72
GuidedDCNet	97,84	97,80	97,79	97,79

trội hai mô hình cây – với Accuracy của cả bốn phương pháp trên OCEANFX đều nằm trong khoảng 88,33%–97,84%, cao hơn khoảng tương ứng trên FLAMENIR (80,55%–91,96%). Khoảng cách giữa bốn phương pháp trên OCEANFX cũng hẹp hơn FLAMENIR, nhất quán với độ phân giải phổ cao hơn nhiều của máy này (2.136 so với 128 điểm bước sóng, Bảng 1) cung cấp nhiều đặc trưng phân biệt hơn cho cả cây quyết định lẫn mạng nơ-ron, thu hẹp phần lợi thế kiến trúc của SMART-NIR/GuidedDCNet.

4.3.2. Đánh giá an toàn thuốc trừ sâu

Bảng 9 cho kết quả cùng thứ hạng với FLAMENIR: SMART-NIR vượt trội hai mô hình cây ở mọi chỉ số, và Accuracy/PR-AUC của XGBoost, LightGBM, SMART-NIR trên OCEANFX (86,00–94,24% / 68,05–90,30%) đều cao hơn bằng tương ứng trên FLAMENIR (81,55–94,73% / 54,53–88,83%), cùng xu hướng quan sát được ở bài toán phân loại thực phẩm.

Đánh giá trên tập kiểm tra độc lập. Tương tự FLAMENIR, trên 100 mẫu OCEANFX tách riêng, Bước 1 đạt Accuracy/Recall/PR-AUC lần lượt là 86,58%/78,04%/67,86% với XGBoost, 86,32%/84,99%/71,84% với LightGBM và 95,05%/96,32%/95,99% với SMART-NIR – một lần nữa gần khớp với kết quả kiểm định chéo ở Bảng 9, riêng SMART-NIR còn cho PR-AUC trên tập kiểm tra độc lập (95,99%) cao hơn cả kiểm định chéo (90,30%), củng cố thêm rằng kết quả kiểm định chéo của phương pháp này không phải do quá khớp vào cách chia fold cụ thể.

Bảng 9. Bước 1 – Phát hiện, máy OCEANFX (trung bình 5 fold theo từng thuốc trừ sâu, %)

Thuốc trừ sâu	XGBoost					LightGBM					SMART-NIR				
	Acc.	Prec.	Rec.	F1	PR-AUC	Acc.	Prec.	Rec.	F1	PR-AUC	Acc.	Prec.	Rec.	F1	PR-AUC
Thiamethoxam	80,09	64,83	81,37	67,01	58,40	80,21	64,89	81,38	67,12	58,82	88,50	72,99	89,19	77,56	83,04
Permethrin	78,10	68,12	81,05	69,83	60,71	78,50	68,36	81,22	70,19	61,33	96,64	93,12	93,91	93,51	95,70
Metalaxyl	80,92	63,10	81,80	65,26	62,75	80,75	63,04	81,83	65,14	63,12	85,98	67,60	87,54	71,69	81,47
Azoxystrobin	93,59	85,34	90,38	87,59	87,82	93,78	85,79	90,45	87,89	88,03	98,46	98,78	94,80	96,67	99,33
Imidacloprid	89,98	72,65	87,36	77,29	70,69	90,18	72,94	87,39	77,58	71,27	97,94	93,28	94,38	93,82	94,73
Difenoconazole	93,66	85,40	90,48	87,67	87,90	93,73	85,58	90,46	87,77	88,10	98,53	98,78	95,06	96,81	99,31
Cypermethrin	75,31	70,16	79,23	70,76	72,45	75,34	70,21	79,32	70,81	72,42	92,10	86,79	91,38	88,77	93,09
Cyhalothrin	83,54	66,58	83,19	69,84	58,35	83,92	66,86	83,28	70,23	58,97	95,03	83,88	92,79	87,60	90,44
Chlorantraniliprol	85,10	62,32	82,34	65,44	48,46	85,06	62,25	82,16	65,34	48,52	85,01	63,44	87,18	66,83	66,02
Chlopyrifos Methyl	98,86	92,79	91,64	92,20	92,26	98,93	93,78	91,49	92,60	92,66	99,44	97,43	94,80	96,07	96,65
Emamectin benzoate	75,10	69,27	79,28	69,87	68,79	75,04	69,28	79,34	69,84	68,93	89,08	81,72	89,37	84,54	89,19
Chlorothalonil	70,43	66,73	76,59	65,64	67,78	70,44	66,72	76,56	65,65	67,77	92,54	86,63	91,54	88,75	92,65
Triadimefon	96,81	72,23	85,78	77,25	68,05	97,18	74,21	85,32	78,62	69,06	98,18	80,78	94,29	86,18	89,97
Cyantraniliprole	91,23	72,03	87,67	76,99	71,09	91,22	72,00	87,57	76,94	71,22	97,92	91,30	94,49	92,81	93,80
Flutolanil	96,93	74,18	86,95	79,08	71,53	96,99	74,49	86,52	79,18	71,75	98,52	84,85	94,09	88,82	90,94
Indoxacarb	95,79	67,31	84,59	72,70	54,18	95,74	67,05	84,01	72,35	54,05	98,80	86,01	94,40	89,63	90,03
Abamectin	78,93	63,24	80,21	64,89	58,79	79,02	63,27	80,21	64,95	58,87	86,22	69,82	88,03	73,93	82,61
Propamocarb.HCL	94,02	64,35	84,21	69,51	54,83	94,92	66,19	83,47	71,35	56,67	99,01	89,81	94,33	91,90	92,40
Chlothianidin	75,56	71,95	79,52	72,33	78,13	75,48	71,91	79,50	72,26	78,17	92,59	88,84	91,74	90,15	94,25
Trung bình	86,00	71,19	83,88	73,75	68,05	86,13	71,52	83,76	73,99	68,41	94,24	85,05	92,28	87,16	90,30

Bảng 10. Bước 2 – Phân loại mức độ, máy OCEANFX (trung bình 5 fold theo từng thuốc trừ sâu, %)

Thuốc trừ sâu	XGBoost					LightGBM					SMART-NIR				
	Acc.	Prec.	Rec.	F1	PR-AUC	Acc.	Prec.	Rec.	F1	PR-AUC	Acc.	Prec.	Rec.	F1	PR-AUC
Thiamethoxam	77,26	61,07	79,61	61,73	42,22	77,86	61,32	79,86	62,23	42,46	85,39	67,10	87,67	71,02	70,40
Permethrin	76,95	63,45	79,96	64,50	50,13	77,31	63,66	80,24	64,85	50,76	94,28	82,97	92,44	86,84	85,93
Metalaxyl	77,75	60,34	80,36	60,90	54,80	78,74	60,74	80,74	61,72	55,13	81,83	63,21	85,39	65,57	75,66
Azoxystrobin	96,58	80,83	90,29	84,82	76,93	96,68	81,34	90,17	85,11	77,65	99,17	96,57	94,82	95,67	93,95
Imidacloprid	82,43	60,50	83,50	62,43	57,34	82,85	60,71	83,70	62,83	57,33	96,99	83,61	93,72	87,78	84,87
Difenoconazole	94,28	85,57	90,59	87,83	84,20	94,31	85,62	90,65	87,88	84,38	98,69	98,91	95,09	96,89	96,50
Cypermethrin	76,52	68,70	80,04	69,86	67,01	76,58	68,76	80,12	69,93	67,40	91,72	84,15	91,04	86,94	90,13
Cyhalothrin	82,20	61,96	82,80	64,24	38,78	83,33	62,54	83,02	65,26	39,54	92,28	72,92	91,24	78,54	73,13
Chlorantraniliprol	94,97	68,52	85,80	73,96	52,32	95,39	69,73	85,76	75,07	53,78	95,16	70,06	92,63	76,62	73,31
Chlopyrifos Methyl	98,89	90,82	90,85	90,83	83,79	98,89	90,88	90,82	90,85	83,53	99,41	95,53	94,70	95,10	92,14
Emamectin benzoate	73,72	68,21	78,56	68,36	65,69	73,65	68,20	78,57	68,32	65,85	87,39	79,36	88,42	82,36	87,36
Chlorothalonil	75,26	61,74	78,43	61,98	47,08	76,19	62,11	78,77	62,73	47,85	85,53	69,13	87,34	73,14	76,83
Triadimefon	87,25	57,23	83,10	59,21	46,19	91,69	62,10	84,83	66,18	47,91	95,87	74,31	92,95	79,53	82,45
Cyantraniliprole	92,82	67,30	86,78	72,69	48,14	93,10	67,78	86,68	73,19	47,72	97,12	80,65	93,86	85,88	81,35
Flutolanil	96,75	73,28	86,93	78,38	58,35	96,80	73,49	86,59	78,44	58,35	98,39	83,81	94,17	88,16	84,72
Indoxacarb	96,68	67,30	84,25	72,71	45,84	97,24	69,86	83,57	74,79	47,39	98,24	78,99	94,17	84,28	83,15
Abamectin	77,88	62,44	79,73	63,63	54,19	78,22	62,61	79,92	63,94	54,36	85,66	68,78	87,79	72,82	79,98
Propamocarb.HCL	96,19	63,86	82,52	69,03	45,98	96,98	66,68	81,43	71,57	46,96	97,60	73,87	94,00	80,11	82,97
Chlothianidin	74,41	71,13	78,86	71,18	76,26	74,49	71,21	78,95	71,27	76,53	92,53	88,67	91,61	89,99	93,57
Trung bình	85,72	68,12	83,31	70,44	57,65	86,33	68,91	83,39	71,38	58,15	93,33	79,61	91,74	83,01	83,60