


Báo cáo tiến độ

Ngày 12 tháng 8 năm 2026



Hình 1. Sơ đồ tổng quan hệ thống, giải quyết đồng thời ba bài toán: phân loại loại thực phẩm, phát hiện sự hiện diện và dự đoán nồng độ thuốc trừ sâu. Mỗi mô hình được huấn luyện theo kiểm định chéo K-Fold (K-Fold cross-validation, $K=5$); dự đoán cuối cùng của một mẫu tổng hợp từ 5 mô hình theo fold bằng bỏ phiếu đa số (majority voting) khi phân loại/phát hiện, hoặc trung bình cộng khi định lượng. Nhánh phát hiện/định lượng (Bước 1 – Bước 2) được lặp lại độc lập cho từng loại trong 19 thuốc trừ sâu khảo sát.

1. Phương pháp

1.1. Tổng quan

Hệ thống được xây dựng nhằm giải quyết đồng thời ba bài toán từ cùng một phổ NIR đầu vào của một mẫu rau củ quả: (1) phân loại loại thực phẩm; (2) phát hiện sự tồn tại của từng loại thuốc bảo vệ thực vật trong mẫu; và (3) dự đoán hàm lượng (nồng độ) của thuốc bảo vệ thực vật đó nếu được xác định là có tồn tại. Sơ đồ tổng quan của hệ thống được minh họa trong Hình 1.

Bài toán (1) được giải quyết độc lập bằng một mô hình SMART-NIR (Mục 1.2) đóng vai trò bộ phân loại đa lớp, với số lớp đầu ra tương ứng số loại rau củ quả (9 lớp). Mô hình được huấn luyện theo kiểm định chéo K-Fold ($K=5$, Mục 3.1.2), tạo ra 5 mô hình độc lập theo từng fold; ở bước suy luận, dự đoán cuối cùng cho một mẫu được tổng hợp từ 5 mô hình này bằng bỏ phiếu đa số (majority voting) thay vì chỉ dùng một mô hình đơn lẻ, giúp giảm phương sai và tăng độ ổn định của kết quả phân loại.


Bài toán (2) và (3) được giải quyết theo một quy trình lại gồm hai bước, lặp lại độc lập cho từng loại trong số 19 thuốc trừ sâu khảo sát. Cả hai bước đều huấn luyện theo kiểm định chéo K-Fold ($K=5$, Mục 3.2.2) và tổng hợp dự đoán từ 5 mô hình theo fold ở bước suy luận:

- **Bước 1 – Phát hiện.** Mô hình XGBoost (Mục 1.3) được sử dụng như một bài toán phân loại nhị phân, xác định thuốc trừ sâu đang xét có tồn tại trong mẫu hay không; giống bài toán (1), quyết định cuối cùng được tổng hợp bằng bỏ phiếu đa số (majority voting) qua 5 mô hình theo fold.
- **Bước 2 – Định lượng.** Chỉ những mẫu được Bước 1 xác định là có tồn tại thuốc trừ sâu mới được đưa tiếp vào Bước 2, tại đó một mô hình SMART-NIR đóng vai trò bộ hồi quy, huấn luyện riêng cho từng thuốc trừ sâu, được dùng để dự đoán giá trị nồng độ; do đầu ra là giá trị liên tục, dự đoán cuối cùng là trung bình cộng của 5 dự đoán theo fold thay vì bỏ phiếu (voting).

Cách tiếp cận theo tầng (cascade) này mang lại ba lợi ích: (i) tránh lãng phí năng lực của mô hình hồi quy vào các mẫu không chứa thuốc trừ sâu, vốn chiếm đa số trong tập dữ liệu; (ii) phản ánh đúng quy trình phân tích thực tế, trong đó bước sàng lọc sự hiện diện luôn được thực hiện trước bước định lượng; và (iii) cho phép đánh giá độc lập độ chính xác của từng giai đoạn – phát hiện và định lượng – thay vì gộp chung thành một chỉ số duy nhất.

1.2. Mô hình SMART-NIR

Kiến trúc Vision Transformer (ViT) nắm bắt tốt đặc trưng toàn cục và dễ mở rộng, nhưng các mô hình ViT truyền thống thường dùng phép chiếu tích chập 3×3 ở bước nhúng đặc trưng, dễ làm mất các đặc tính tín hiệu quan trọng. SMART-NIR khắc phục hạn chế này bằng cách để mỗi token nắm bắt một tập đặc trưng tín hiệu phong phú hơn, thông qua bốn mô-đun nối tiếp minh họa trong Hình 2: (1) Khối Multi-kernel trích xuất đặc trưng thô từ phổ NIR ở nhiều tỉ lệ khác nhau; (2) Patch + Position Embedding mã hóa và định vị các đặc trưng thô thành chuỗi token; (3) Khối mã hóa Transformer tinh chỉnh chuỗi token thành đặc trưng giàu thông tin; (4) KAN đóng vai trò bộ phân loại hoặc hồi quy ở đầu ra, tùy theo tác vụ đích.



Hình 2. Kiến trúc mô hình SMART-NIR

1.2.1. Khối Multi-kernel

Phổ NIR đầu vào được biểu diễn dưới dạng vector $\mathbf{X} \in \mathbb{R}^{L \times C}$, với L là độ dài phổ (số bước sóng) và $C = 1$ là số kênh. Khối Multi-kernel gồm bốn nhánh tích chập song song với kích thước nhân lần lượt là 4×1 , 8×1 , 16×1 và 32×1 , cho phép trích xuất đặc trưng thô ở nhiều tỉ lệ khác nhau. Ở nhánh thứ i ($i \in \{1, 2, 3, 4\}$), một nhân tích chập $\mathbf{W}_i$ có kích thước $K_i = (C_{out}, K_w, K_h)$ – với C_{out} là số kênh đầu ra, K_w và K_h lần lượt là chiều rộng và chiều cao của nhân – được áp dụng lên $\mathbf{X}$ với bước nhảy chung $S = (4, 1)$ và đệm P_i riêng cho từng nhánh:

$$\begin{aligned} \mathbf{F}_1 &= \text{Conv}(\mathbf{X}, \mathbf{W}_1, K_1=(C_{out}, 4, 1), S, P_1=(0, 0)) \\ \mathbf{F}_2 &= \text{Conv}(\mathbf{X}, \mathbf{W}_2, K_2=(C_{out}, 8, 1), S, P_2=(3, 0)) \\ \mathbf{F}_3 &= \text{Conv}(\mathbf{X}, \mathbf{W}_3, K_3=(C_{out}, 16, 1), S, P_3=(7, 0)) \\ \mathbf{F}_4 &= \text{Conv}(\mathbf{X}, \mathbf{W}_4, K_4=(C_{out}, 32, 1), S, P_4=(15, 0)) \end{aligned} \quad (1)$$

Bốn đặc trưng thô $\mathbf{F}_1, \mathbf{F}_2, \mathbf{F}_3, \mathbf{F}_4$ được nối theo chiều kênh, tạo thành đầu ra $\mathbf{X}_0$ của khối Multi-kernel.

1.2.2. Patch + Position Embedding

Đặc trưng thô $\mathbf{X}_0$ được chuyển vị và làm phẳng theo chiều không gian để tạo thành chuỗi token, sau đó nối với một token phân loại học được $\mathbf{x}_{cls}$ và cộng thêm embedding vị trí học được $\mathbf{E}_{pos}$, tạo thành chuỗi đầu vào $\mathbf{X}_1$ cho khối mã hóa Transformer:

$$\mathbf{X}_1 = \text{Concat}(\mathbf{x}_{cls}, \mathbf{X}_0^T) + \mathbf{E}_{pos} \quad (2)$$

1.2.3. Khối mã hóa Transformer

Khối mã hóa Transformer nắm bắt các phụ thuộc phức tạp trong chuỗi token thông qua một chồng lớp, mỗi lớp gồm cơ chế tự chú ý đa đầu (Multi-Head Self-Attention – MHSA) nối tiếp một mạng truyền thẳng (feedforward), có chuẩn hóa lớp (Layer Normalization) trước mỗi khối và kết nối tắt (skip connection) để giảm hiện tượng tiêu biến gradient.

Tự chú ý đa đầu: Từ chuỗi đầu vào $\mathbf{X}_1 \in \mathbb{R}^{(H_{out}+1) \times C_{out}}$ (H_{out} là số token thô, chưa tính token phân loại), ba ma trận Query, Key, Value được tạo ra bằng phép chiếu tuyến tính học được: $\mathbf{Q} = \mathbf{X}_1 \mathbf{W}_Q$, $\mathbf{K} = \mathbf{X}_1 \mathbf{W}_K$, $\mathbf{V} = \mathbf{X}_1 \mathbf{W}_V$, với $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$ là các ma trận trọng số có thể học. Trọng số chú ý giữa mỗi cặp token được tính bằng tích vô hướng chuẩn hóa giữa $\mathbf{Q}$ và $\mathbf{K}$, qua hàm softmax để phản ánh mức độ quan trọng tương đối của từng token trong chuỗi:

$$SA(\mathbf{X}_1) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{H_{out}+1}}\right) \mathbf{V} \quad (3)$$

Cơ chế MHSA mở rộng tự chú ý (self-attention) chuẩn bằng cách thực hiện N_h phép tính chú ý song song, gọi là các đầu chú ý (head); mỗi đầu chiếu tuyến tính riêng để nắm bắt một khía cạnh quan hệ khác nhau trong dữ liệu, rồi các đầu ra được nối lại và biến đổi tuyến tính để tạo kết quả cuối cùng:

$$\begin{aligned} MHSA(\mathbf{X}_1) &= \text{Concat}(SA_1(\mathbf{X}_1), SA_2(\mathbf{X}_1), \\ &\quad \dots, SA_{N_h}(\mathbf{X}_1)) \end{aligned} \quad (4)$$


Dual-MLP: Để giảm chi phí tính toán mà vẫn duy trì, thậm chí cải thiện hiệu năng, token đầu ra $\mathbf{z}$ của khối MHSA được tách theo chiều cuối thành hai nửa bằng nhau $\mathbf{m}$ và $\mathbf{n}$, mỗi nửa đi qua một nhánh biến đổi tuyến tính riêng biệt rồi nối lại:

$$\text{DUAL-MLP} = \text{Concat}(\mathbf{W}_{fc4} \text{GELU}(\mathbf{W}_{fc2} \mathbf{m}), \mathbf{W}_{fc3} \text{GELU}(\mathbf{W}_{fc1} \mathbf{n})) \quad (5)$$

với $\mathbf{W}_{fc1}, \mathbf{W}_{fc2}, \mathbf{W}_{fc3}, \mathbf{W}_{fc4}$ là các ma trận trọng số học được của bốn nhánh tuyến tính minh họa ở Hình 2. Việc xử lý song song hai nửa đặc trưng theo cách này giúp mô hình học được các mẫu đặc trưng đa dạng hơn mà không làm phát sinh chi phí tính toán đáng kể.

1.2.4. Bộ phân loại / hồi quy

Ở đầu ra, kiến trúc KAN đóng vai trò bộ phân loại hoặc hồi quy, với hai lớp ẩn kích thước giảm dần (32, 16), như minh họa ở Hình 3. Khác với MLP truyền thống dùng trọng số tuyến tính cho mỗi kết nối, KAN thay thế các ma trận trọng số bằng các hàm một biến có thể học được, áp dụng độc lập theo từng chiều của đầu vào.



Hình 3. Kiến trúc mô hình KAN

1.3. Mô hình XGBoost

XGBoost (Extreme Gradient Boosting) là thuật toán học tập hợp (ensemble learning) thuộc họ Gradient Boosting Decision Trees (GBDT), được phát triển để khắc phục các hạn chế của Gradient Boosting truyền thống về hiệu năng, khả năng mở rộng và độ ổn định trên dữ liệu lớn, phức tạp – nhờ đó trở thành một trong những phương pháp phổ biến nhất cho bài toán phân loại và hồi quy.

Cốt lõi của XGBoost là ý tưởng tăng cường tuần tự (boosting): một tập hợp cây quyết định (weak learners) được huấn luyện tuần tự, mỗi cây mới học để bù đắp sai lệch mà các cây trước đó chưa dự đoán tốt, thay vì huấn luyện độc lập như bagging. Gọi y_i và $\hat{y}_i$ lần lượt là nhãn

thực và giá trị dự đoán của mẫu i , hàm mục tiêu được tối ưu ở mỗi vòng lặp có dạng

$$L = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k), \quad (6)$$

trong đó $l(\cdot)$ là hàm mất mát đo độ sai lệch giữa y_i và $\hat{y}_i$, còn $\Omega(f_k)$ là số hạng điều chuẩn áp dụng cho cây thứ k (ký hiệu f_k), giúp kiểm soát độ phức tạp của cây và giảm nguy cơ quá khớp.

Khác với Gradient Boosting truyền thống chỉ dùng gradient bậc nhất, XGBoost tận dụng khai triển Taylor bậc hai của hàm mất mát – kết hợp cả gradient (đạo hàm bậc 1) và Hessian (đạo hàm bậc 2) – giúp ước lượng chính xác hơn mức cải thiện khi thêm một cây mới, nhờ đó quá trình tối ưu hội tụ nhanh và ổn định hơn. Mỗi cây được xây dựng theo hướng tham lam, với tiêu chí chia nhánh dựa trên mức độ giảm của hàm mục tiêu, hỗ trợ cả chiến lược mở rộng theo chiều sâu (depth-wise) lẫn mở rộng theo nút mang lại lợi ích lớn nhất (leaf-wise), kèm cơ chế cắt tỉa dựa trên độ lợi (gain) để loại sớm các nhánh không mang lại cải thiện đáng kể.

Nhờ sự cân bằng giữa độ chính xác, khả năng diễn giải và hiệu năng tính toán, XGBoost được ứng dụng rộng rãi và đóng vai trò quan trọng trong hệ sinh thái học máy hiện đại.

2. Dữ liệu

Bộ dữ liệu gồm phổ NIR thu từ hai máy quang phổ FLAMENIR và OCEANFX trên chín loại rau củ quả phổ biến tại Việt Nam, kèm nhãn nồng độ (mg/kg; giá trị -1 nghĩa là không phát hiện) của 19 loại thuốc trừ sâu, được xác định bằng phương pháp phân tích hóa học chuyên sâu trong phòng thí nghiệm. Phần này trình bày thống kê mô tả (EDA) trên từng máy: phân bố mẫu theo loại rau củ quả, tỉ lệ nhiễm từng loại thuốc trừ sâu, đặc điểm phổ NIR theo từng loại, và phân bố nồng độ trong các mẫu có phát hiện.

2.1. Thống kê mô tả

Bảng 1. Thông số chung của hai máy quang phổ

Thông số	FLAMENIR	OCEANFX
Số lượng mẫu	173.252	126.147*
Số lượng bước sóng	128	2.136
Số lượng lớp phân loại	9	9
Số thuốc trừ sâu cần dự đoán	19	19

* đã loại 1 mẫu ngoại lai do lỗi cảm biến.

Bảng 1 cho thấy sự đánh đổi giữa hai máy: FLAMENIR thu được nhiều mẫu hơn (173.252 so với 126.147) nhưng với độ phân giải phổ thấp hơn nhiều (128 so với 2.136 điểm bước sóng) so với OCEANFX. Cả hai máy đều khảo sát cùng 9 loại rau củ quả và 19 thuốc trừ sâu, cho phép so sánh trực tiếp hiệu năng mô hình giữa hai cấu hình phân cứng khác nhau ở Mục 4.

Bảng 2 cho thấy phân bố mẫu giữa các loại rau củ quả không hoàn toàn cân bằng. Trên FLAMENIR, chênh lệch giữa loại nhiều mẫu nhất (Cà Rốt, 23.151) và ít mẫu nhất (Xà Lách, 15.597) khoảng 1,5 lần; trên OCEANFX, mức

Bảng 2. Số lượng mẫu theo loại rau củ quả

Loại	Số lượng mẫu	
	FLAMENIR	OCEANFX
Khổ Qua	21.833	17.683
Mồng Tơi	15.636	12.187
Cải Thừa	21.269	16.905
Cà Chua	16.672	12.289
Cải Bẹ Xanh	15.691	15.916
Dưa Leo	23.069	15.566
Xà Lách	15.597	7.868
Đậu Cove	20.334	16.256
Cà Rốt	23.151	11.477

chênh lệch rõ rệt hơn, khoảng 2,2 lần giữa Khổ Qua (17.683) và Xà Lách (7.868) – Xà Lách là loại thiếu số trên cả hai máy. Mất cân bằng này là một trong các lý do bài toán phân loại (Mục 1.2) dùng kiểm định chéo K-Fold phân tầng (Stratified K-Fold) và theo dõi cả Precision/Recall/F1-score theo trung bình không trọng số qua các lớp (macro-average) thay vì chỉ Accuracy.

Bảng 3. Số lượng mẫu không chứa / có chứa từng thuốc trừ sâu


Thuốc trừ sâu	FLAMENIR		OCEANFX	
	Không chứa	Có chứa	Không chứa	Có chứa
Thiamethoxam	159.315	13.937	114.054	12.093
Permethrin	148.443	24.809	100.283	25.864
Metalaxyl	169.091	4.161	121.745	4.402
Azoxystrobin	160.518	12.734	115.526	10.621
Imidacloprid	154.619	18.633	121.747	4.400
Difenoconazole	160.624	12.628	115.807	10.340
Cypermethrin	160.330	12.922	113.326	12.821
Cyhalothrin	169.934	3.318	120.598	5.549
Chlorantraniliprol	171.622	1.630	123.260	2.887
Chlorpyrifos Methyl	171.371	1.881	122.342	3.805
Emamectin benzoate	160.062	13.190	125.115	1.032
Chlorothalonil	158.417	14.835	117.761	8.386
Triadimefon	173.252	0	126.147	0
Cyantraniliprole	163.202	10.050	126.147	0
Flutolanil	173.252	0	126.147	0
Indoxacarb	166.359	6.893	120.073	6.074
Abamectin	162.971	10.281	119.094	7.053
Propamocarb.HCL	173.252	0	126.147	0
Chlothianidin	166.446	6.806	120.073	6.074

các dòng tô đỏ: có ít nhất một máy với 0 mẫu dương (không thể huấn luyện mô hình phát hiện/hồi quy tương ứng trên máy đó).


Bảng 3 cho thấy mức mất cân bằng lớp nghiêm trọng hơn nhiều so với bài toán phân loại: đa số thuốc trừ sâu chỉ xuất hiện trong dưới 10% tổng số mẫu, với Permethrin là thuốc trừ sâu phổ biến nhất trên cả hai máy (14,3% ở FLAMENIR, 20,5% ở OCEANFX). Ba thuốc trừ sâu (Triadimefon, Flutolanil, Propamocarb.HCL) không có mẫu dương nào trên cả hai máy; riêng Cyantraniliprole có 10.050 mẫu dương trên FLAMENIR nhưng bằng 0 trên OCEANFX, phản ánh sự khác biệt giữa hai đợt lấy mẫu chứ không phải do bản thân thiết bị đo. Các thuốc trừ sâu không có mẫu dương trên một máy nào đó khiến không thể huấn luyện được mô hình phát hiện/hồi quy tương ứng, thể hiện qua các giá trị NaN ở Mục 4.

2.2. Trục quan hóa dữ liệu

Hình 4 cho thấy các loại rau củ quả có hình dạng phổ NIR khá tương đồng trên cùng một máy (cùng vị trí đỉnh hấp



(a) Máy FLAMENIR



(b) Máy OCEANFX

Hình 4. Phổ NIR trung bình (đường liền) và dải độ lệch chuẩn (vùng tô) theo loại rau củ quả

thụ) nhưng khác nhau rõ rệt về cường độ tuyệt đối – ở FLAMENIR, Cải Bẹ Xanh và Xà Lách cho cường độ cao nhất còn Khổ Qua thấp nhất; đây là cơ sở để mô hình phân biệt được loại rau củ quả từ phổ thô. Phổ từ OCEANFX (Hình 4b) có độ phân giải bước sóng cao hơn nhiều (2.136 so với 128 điểm) và bộc lộ rõ hai đỉnh hấp thụ chính, cùng dải độ lệch chuẩn rộng hơn ở vùng bước sóng thấp, phản ánh mức biến thiên tín hiệu cao hơn giữa các cá thể mẫu trong vùng này.

Hình 5 cho thấy tỉ lệ nhiễm phân bố không đồng đều giữa các loại rau củ quả và giữa hai máy: ở FLAMENIR, Cà Chua có tỉ lệ nhiễm Thiamethoxam và Chlothianidin cao nhất trong khi Khổ Qua nổi bật với Cypermethrin và Imidacloprid; ở OCEANFX, ô có tỉ lệ nhiễm cao nhất toàn bảng là Thiamethoxam tại Cà Chua (43,7%), theo sau là Permethrin tại Xà Lách (41,6%) – Permethrin cũng là thuốc trừ sâu phổ biến nhất trên máy này, với tỉ lệ trên 20% ở nhiều loại rau củ quả khác nhau.

Về mức độ đồng nhiễm: trong tổng số 173.252 mẫu FLAMENIR, 47.635 mẫu (27,5%) không phát hiện thuốc trừ sâu nào (mẫu sạch), 96.021 mẫu (55,4%) chỉ chứa đúng một loại, và 29.596 mẫu (17,1%) đồng thời chứa từ hai loại trở lên – trong đó 563 mẫu chứa cùng lúc cả bốn loại. Ở OCEANFX, trong tổng số 126.147 mẫu, 47.047 mẫu (37,3%) là mẫu sạch, 51.266 mẫu (40,7%) chứa đúng một loại, và 27.834 mẫu (22,1%) đồng thời chứa từ hai loại trở lên – trong đó 1.003 mẫu chứa cả bốn loại. Tỉ lệ đồng nhiễm ở OCEANFX cao hơn FLAMENIR (22,1% so với 17,1%), một khác biệt cần lưu ý khi so sánh hiệu năng phát hiện giữa hai máy ở Mục 4. Đồng nhiễm nhiều thuốc trừ sâu cũng là một trong những lý do khiến việc tách bài toán phát hiện thành 19 mô hình nhị phân độc lập (Mục 1.3) phù hợp hơn một bộ phân loại đa nhãn đơn lẻ giả định các nhãn độc lập tuyệt đối.

3. Thiết lập thực nghiệm

Tất cả các thí nghiệm được thực hiện trên hệ điều hành Ubuntu 22.04, sử dụng PyTorch 2.9.1 và Python 3.12.11 với CUDA hỗ trợ, chạy trên GPU NVIDIA RTX 5090 Ti và được trang bị CPU Intel® Xeon® E5-2696 v3 @ 2.30 GHz.

3.1. Phân loại rau củ quả

3.1.1. Tiền xử lý dữ liệu


Dữ liệu phổ NIR thường chịu ảnh hưởng của nhiễu, tán xạ và sai lệch đường nền, do đó cần được tiền xử lý trước khi đưa vào mô hình phân loại. Trước hết, dữ liệu được làm sạch nhằm loại bỏ các phổ lỗi và giá trị ngoại lai. Tiếp theo, kỹ thuật Savitzky–Golay được sử dụng để giảm nhiễu và hiệu chỉnh đường nền giúp làm nổi bật các đặc trưng quan trọng.

Để hạn chế ảnh hưởng của tán xạ ánh sáng, phương pháp chuẩn hóa biến số chuẩn (Standard Normal Variate – SNV) được sử dụng. Sau đó, dữ liệu được chuẩn hóa về cùng thang đo nhằm đảm bảo quá trình học ổn định. Cuối cùng, dữ liệu được chia thành các tập huấn luyện và kiểm tra phục vụ cho bài toán phân loại.


3.1.2. Chi tiết huấn luyện

Quá trình huấn luyện mô hình phân loại phổ NIR được triển khai bằng PyTorch, với chiến lược kiểm định chéo K-Fold nhằm đánh giá độ ổn định và khả năng tổng quát hóa của mô hình. Cụ thể, dữ liệu được chia thành 5 fold theo phương pháp K-Fold phân tầng (Stratified K-Fold), đảm bảo phân bố nhãn giữa các tập huấn luyện và kiểm tra được giữ cân bằng.

Trước mỗi fold, dữ liệu huấn luyện được sử dụng để ước lượng tham số chuẩn hóa và ánh xạ nhẵn, sau đó áp dụng thống nhất cho cả tập huấn luyện và tập kiểm tra nhằm tránh rò rỉ thông tin. Trong mỗi fold, dữ liệu được lấy mẫu và gom thành lô (batch) kích thước 512, giúp tăng hiệu quả huấn luyện trên GPU.



(a) Máy FLAMENIR



(b) Máy OCEANFX

Hình 5. Tỷ lệ (%), một chữ số thập phân) mẫu có chứa từng thuốc trừ sâu theo loại rau củ quả, dùng chung thang màu giữa hai máy để so sánh

Mô hình SMART-NIR được khởi tạo với các tham số chính bao gồm: (1) Chiều dài tín hiệu đầu vào bằng độ dài phổ sau tiền xử lý; (2) Số kênh đầu ra cho mỗi nhánh đa kernel là 64; (3) Kích thước không gian đặc trưng là 128; (4) Số tầng Transformer là 3 với 4 đầu tự chú ý mỗi tầng; (5) Bộ phân loại cuối sử dụng KAN với số lớp đầu ra tương ứng với số nhãn trong tập dữ liệu.

Hàm mất mát được sử dụng là Focal Loss ($\gamma = 2$), với trọng số α của mỗi lớp tỉ lệ nghịch với tần suất lớp đó trong fold huấn luyện. So với hàm entropy chéo (Cross-Entropy) thông thường, Focal Loss giảm đóng góp gradient của các mẫu dễ (thường thuộc lớp đa số) và tập trung hơn vào lớp thiếu số, phù hợp với đặc điểm mất cân bằng dữ liệu đã nêu ở Mục 2.1. Quá trình tối ưu tham số được thực hiện bằng trình tối ưu AdamW (suy giảm trọng số/weight decay 10^{-4}) nhằm hạn chế quá khớp (overfitting). Tốc độ học được điều chỉnh theo lịch trình gồm hai giai đoạn: khởi động (warmup) tuyến tính trong 10 lượt huấn luyện đầu (epoch, 5% tổng số lượt), tăng dần từ 10^{-4} lên 10^{-3} , sau đó giảm dần về gần 0 theo lịch suy giảm dạng cos (Cosine Annealing) trong các lượt còn lại. Trong mỗi lượt huấn luyện, mô


hình được huấn luyện trên tập huấn luyện với cơ chế lan truyền ngược, sau đó được đánh giá trên tập đánh giá ở chế độ suy luận theo các tiêu chí trình bày ở Mục 4.1. Cơ chế dừng sớm (early stopping) được áp dụng dựa trên độ chính xác trên tập đánh giá, với ngưỡng kiên nhẫn là 10 epoch: mô hình đạt độ chính xác kiểm tra cao nhất sẽ được lưu lại, và quá trình huấn luyện dừng sớm nếu không có cải thiện trong nhiều epoch liên tiếp.

3.2. Dự đoán hàm lượng các thuốc trừ sâu có trong mẫu


3.2.1. Tiền xử lý dữ liệu

Tương tự với quy trình tiền xử lý ở bài toán phân loại, dữ liệu phổ NIR ban đầu được làm sạch nhằm loại bỏ các phổ lỗi và giá trị ngoại lai, sau đó áp dụng Savitzky–Golay và SNV để làm nổi bật các đặc trưng quan trọng và hạn chế ảnh hưởng của tán xạ ánh sáng.

Toàn bộ dữ liệu (kể cả mất cân bằng) được giữ nguyên, không loại bớt mẫu không chứa thuốc trừ sâu, nhằm không lãng phí thông tin từ các mẫu âm; mất cân bằng nhãn được xử lý trực tiếp trong quá trình huấn luyện XGBoost (Mục 1.3, Bước 1) thông qua trọng số scale_pos_weight.



(a) Máy FLAMENIR



(b) Máy OCEANFX

Hình 6. Phân bố nồng độ (chuẩn hóa 0–1 theo từng chất) trong các mẫu có phát hiện

Đối với bài toán hồi quy nồng độ (Bước 2), biến mục tiêu được biến đổi log ($\log(1 + y)$) trước khi chuẩn hóa Z-score theo từng fold, nhằm giảm độ lệch phải của phân bố nồng độ (đa số giá trị nhỏ, một số ít giá trị lớn) và ổn định quá trình học; các chỉ số MAE, RMSE, R^2 báo cáo ở Mục 4 được tính sau khi biến đổi ngược dự đoán về đơn vị nồng độ gốc (mg/kg). Cuối cùng, dữ liệu được chia thành các tập huấn luyện và kiểm tra phục vụ cho bài toán phát hiện và dự đoán hàm lượng thuốc trừ sâu có trong mẫu.

3.2.2. Chi tiết huấn luyện

Một chiến lược huấn luyện hai bước được sử dụng nhằm xử lý hiệu quả bài toán phân tích phổ NIR với nhiều thuốc trừ sâu khác nhau. Cách tiếp cận này cho phép tách biệt rõ ràng giữa bài toán phát hiện sự hiện diện của thuốc trừ sâu và bài toán ước lượng nồng độ, từ đó nâng cao độ ổn định và độ chính xác của toàn hệ thống.

Bước 1: Ở bước đầu tiên, mỗi thuốc trừ sâu được xem như một bài toán phân loại nhị phân độc lập, trong đó mục tiêu là xác định liệu thuốc trừ sâu đó có xuất hiện trong mẫu hay không. Nhãn được xây dựng bằng cách ánh xạ giá trị đo: các mẫu có giá trị lớn hơn 0 được gán nhãn 1 (có thuốc trừ sâu), trong khi các mẫu có giá trị -1 được gán nhãn 0 (không có thuốc trừ sâu). Quá trình huấn luyện sử dụng kiểm định chéo K-Fold phân tầng (5 fold) để đảm bảo phân bố nhãn cân bằng giữa các tập.

Mô hình được huấn luyện bằng XGBoost với hàm mục tiêu binary logistic, kết hợp cơ chế dừng sớm dựa trên log-loss của tập kiểm tra. Trọng số `scale_pos_weight` được đặt bằng tỉ lệ số mẫu âm/dương của fold huấn luyện để bù đắp mất cân bằng nhãn mà không cần loại bỏ dữ liệu (như đã nêu ở Mục 3.2.1). Độ phức tạp cây (số cây, độ sâu tối đa, tốc độ học) được điều chỉnh theo số mẫu dương của từng

thuốc trừ sâu – thuốc có ít mẫu dương hơn dùng cây nông và ít cây hơn để giảm nguy cơ quá khớp.

Vì `scale_pos_weight` làm lệch xác suất đầu ra của mô hình khỏi xác suất thực, một bước hiệu chỉnh Platt scaling (hồi quy logistic một chiều) được fit trên chính dự đoán của tập huấn luyện, rồi áp dụng lại cho tập kiểm tra để tránh rò rỉ thông tin.

Thay vì cố định ngưỡng phân loại ở 0,5, ngưỡng quyết định được chọn tự động bằng cách quét toàn bộ đường cong Precision-Recall (trên xác suất đã hiệu chỉnh của *tập huấn luyện*, cùng lý do tránh rò rỉ như bước hiệu chỉnh Platt scaling) và chọn ngưỡng cho Precision cao nhất trong số các ngưỡng đạt Recall lớp dương $\geq 0,9$; nếu không ngưỡng nào đạt được mục tiêu này, ngưỡng cho Recall cao nhất được dùng thay thế. Lựa chọn này phản ánh đặc thù bài toán an toàn thực phẩm, nơi bỏ sót một mẫu thực sự có thuốc trừ sâu (false negative) gây hậu quả nghiêm trọng hơn nhiều so với một cảnh báo giả (false positive) cần kiểm tra lại. Ngưỡng được lưu lại cùng mô hình và bộ hiệu chỉnh để tái sử dụng khi suy luận.

Sau khi huấn luyện, mô hình được đánh giá theo các tiêu chí phân loại ở Mục 4.1, cùng với PR-AUC và Brier score trước/sau hiệu chỉnh để theo dõi thêm chất lượng xác suất dự đoán; do ngưỡng được tối ưu theo Recall thay vì mặc định 0,5, PR-AUC (không phụ thuộc ngưỡng) là chỉ số đáng tin cậy hơn Accuracy/F1 khi so sánh hiệu năng phát hiện giữa các thuốc trừ sâu.

Bước này đóng vai trò như một bộ lọc (screening stage), giúp loại bỏ các mẫu không chứa thuốc trừ sâu trước khi thực hiện hồi quy nồng độ.

Bước 2: Ở bước thứ hai, chỉ các mẫu có giá trị nồng độ hợp lệ (khác -1) mới được sử dụng để huấn luyện mô hình hồi quy. Với mỗi thuốc trừ sâu, một mô hình SMART-NIR

riêng biệt được huấn luyện nhằm dự đoán chính xác giá trị nồng độ từ phổ NIR.

Dữ liệu được chia theo K-Fold phân tầng (5 fold) trên các nhóm phân vị (quantile bin) của nồng độ mục tiêu, giúp mỗi fold có phân bố nồng độ tương đồng nhau thay vì lệch ngẫu nhiên như K-Fold thường; với thuốc trừ sâu không đủ dữ liệu để chia nhóm phân vị, phương pháp tự động chuyển về K-Fold thường. Trước mỗi fold, tham số chuẩn hóa của phổ và của biến mục tiêu đã qua biến đổi log (Mục 3.2.1) được ước lượng từ tập huấn luyện và áp dụng thống nhất cho tập kiểm tra. Mô hình SMART-NIR được cấu hình với kiến trúc Transformer đa kernel và bộ hồi quy KAN ở đầu ra.

Quá trình huấn luyện sử dụng Mean Squared Error (MSE), tính trên biến mục tiêu đã chuẩn hóa, làm hàm mất mát, cùng Adam optimizer với tốc độ học ban đầu 10^{-3} . Để cải thiện khả năng hội tụ, ReduceLROnPlateau được áp dụng nhằm điều chỉnh tốc độ học dựa trên giá trị hàm mất mát trên tập đánh giá. Đồng thời, cơ chế dừng sớm được sử dụng để tránh quá khớp.

Mô hình đạt giá trị hàm mất mát trên tập đánh giá (không gian đã chuẩn hóa) thấp nhất trong mỗi fold sẽ được lưu lại, cùng với lịch sử huấn luyện và các biểu đồ đánh giá. Các chỉ số MAE, RMSE và R^2 báo cáo ở Mục 4 được tính theo các tiêu chí ở Mục 4.1, sau khi biến đổi ngược dự đoán và nhãn thực về đơn vị nồng độ gốc để phản ánh đúng sai số thực tế thay vì sai số trên không gian đã chuẩn hóa.

4. Kết quả

4.1. Tiêu chí đánh giá

Hiệu năng mô hình được đánh giá bằng bộ chỉ số phù hợp với từng loại bài toán: phân loại (loại thực phẩm, Mục 1.2; phát hiện thuốc trừ sâu, Mục 1.3) và hồi quy (dự đoán nồng độ, Bước 2 của Mục 1.3).

Chỉ số phân loại. Gọi C là số lớp; với mỗi lớp c , gọi TP_c , FP_c , FN_c lần lượt là số mẫu dương thật, dương giả và âm giả của lớp đó trên tập kiểm tra. Accuracy là tỉ lệ mẫu dự đoán đúng trên tổng số mẫu, trong khi Precision, Recall và F1-score được tính theo trung bình không trọng số qua các lớp (macro-average) để không bị chi phối bởi lớp đa số, phù hợp với đặc điểm mất cân bằng dữ liệu đã nêu ở Mục 2.1:

$$\begin{aligned} \text{Precision} &= \frac{1}{C} \sum_{c=1}^C \text{Precision}_c, \\ \text{Recall} &= \frac{1}{C} \sum_{c=1}^C \text{Recall}_c, \\ F1 &= \frac{1}{C} \sum_{c=1}^C F1_c \end{aligned} \quad (8)$$

Với bài toán phát hiện thuốc trừ sâu (Bước 1, nhị phân), $C = 2$.

Chỉ số bổ sung cho Bước 1. Vì Bước 1 huấn luyện trên dữ liệu mất cân bằng với trọng số `scale_pos_weight` (Mục 1.3), hai chỉ số bổ sung được theo dõi cùng Accuracy/Precision/Recall/F1: PR-AUC (diện tích dưới đường cong Precision-Recall khi quét ngưỡng phân loại), ít nhạy với mất cân bằng lớp hơn ROC-AUC; và Brier score – sai số bình phương trung bình giữa xác suất dự đoán $\hat{p}_i$ và nhãn thực $l_i \in \{0, 1\}$, $\text{Brier} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - l_i)^2$ – đo chất lượng hiệu chỉnh xác suất, được báo cáo trước và sau bước Platt scaling để định lượng mức cải thiện.

Chỉ số hồi quy. Với n mẫu trong tập kiểm tra, y_i và $\hat{y}_i$ lần lượt là nồng độ thực và nồng độ dự đoán của mẫu i , và $\bar{y}$ là nồng độ thực trung bình trên tập kiểm tra, hiệu năng hồi quy được đo bằng MAE, RMSE và hệ số xác định R^2 :

$$\begin{aligned} \text{MAE} &= \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \\ \text{RMSE} &= \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \\ R^2 &= 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \end{aligned} \quad (9)$$

MAE và RMSE càng nhỏ và R^2 càng gần 1 thể hiện mô hình dự đoán nồng độ càng chính xác.

4.2. Máy FLAMENIR

4.2.1. Phân loại rau củ quả

Bảng 4. Kết quả phân loại rau củ quả – máy FLAMENIR

Fold	Accuracy	Precision	Recall	F1-Score
Fold 1	95,17%	94,79%	94,81%	94,80%
Fold 2	94,77%	94,33%	94,37%	94,35%
Fold 3	92,49%	91,86%	91,97%	91,89%
Fold 4	93,16%	92,59%	92,64%	92,60%
Fold 5	94,34%	93,91%	93,98%	93,94%
Trung bình	93,98$\pm$1,01 %	93,50$\pm$1,10 %	93,55$\pm$1,07 %	93,51$\pm$1,10 %

Độ chính xác dao động từ 92,49% (Fold 3) đến 95,17% (Fold 1), chênh lệch khoảng 2,7 điểm % giữa các fold – mức dao động vừa phải, cho thấy mô hình khá ổn định qua các cách chia dữ liệu khác nhau. Precision và Recall luôn sát nhau ở mọi fold, phù hợp với việc dùng Focal Loss cùng trọng số theo tần suất lớp (Mục 3.1.2) để cân bằng ảnh hưởng giữa 9 loại rau củ quả.

$$\begin{aligned} \text{Precision}_c &= \frac{TP_c}{TP_c + FP_c}, \quad \text{Recall}_c = \frac{TP_c}{TP_c + FN_c}, \\ F1_c &= \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \end{aligned} \quad (7)$$

4.2.2. Dự đoán hàm lượng các thuốc trừ sâu có trong mẫu

a/ Phát hiện thuốc trừ sâu

Ngưỡng quyết định (threshold) của mỗi fold được chọn tự động nhằm đạt Recall lớp dương $\geq 0,9$ với Precision cao nhất có thể, thay vì cố định ở 0,5 (chi tiết ở Mục 3.2.2) – phù hợp hơn với bài toán an toàn thực phẩm, nơi bỏ sót một mẫu có thuốc trừ sâu thật (false negative) nguy hiểm hơn một cảnh báo giả (false positive). Vì vậy Accuracy và F1 (theo macro-average, tính trên cả hai lớp) không còn là chỉ số chính để đánh giá – PR-AUC (không phụ thuộc ngưỡng) phản ánh đúng hơn khả năng phân biệt của mô hình.

Bảng 5. Kết quả phát hiện thuốc trừ sâu (trung bình 5-fold) – máy FLAMENIR

Thuốc trừ sâu	Ngưỡng	Acc.	Prec.	Recall	F1	PR-AUC
Thiamethoxam	0,154	90,66%	71,52%	84,16%	75,80%	0,630
Permethrin	0,105	72,84%	63,68%	75,55%	63,73%	0,482
Metalaxyl	0,285	97,61%	74,66%	81,77%	77,73%	0,627
Azoxystrobin	0,086	87,27%	65,97%	82,64%	69,95%	0,529
Imidacloprid	0,117	83,60%	66,92%	80,21%	70,04%	0,521
Difenoconazole	0,088	87,61%	66,20%	82,77%	70,27%	0,533
Cypermethrin	0,129	88,29%	67,05%	82,31%	71,17%	0,521
Cyhalothrin	0,814	99,21%	95,52%	82,27%	87,72%	0,868
Chlorantraniliprol	0,678	99,29%	86,02%	70,08%	75,68%	0,571
Chlopyrifos Methyl	0,935	99,70%	98,96%	86,97%	92,07%	0,953
Emamectin benzoate	0,126	89,07%	67,77%	80,42%	71,66%	0,532
Chlorothalonil	0,163	89,47%	70,47%	83,11%	74,57%	0,570
Triadimefon		NaN (0 mẫu dương)				
Cyantraniliprole	0,091	88,94%	64,16%	79,99%	68,09%	0,455
Flutolanil		NaN (0 mẫu dương)				
Indoxacarb	0,201	95,43%	71,88%	82,52%	75,98%	0,591
Abamectin	0,088	89,74%	64,95%	78,61%	68,82%	0,481
Propamocarb.HCL		NaN (0 mẫu dương)				
Chlothianidin	0,096	93,87%	67,23%	82,46%	72,03%	0,515

Ghi chú: NaN ứng với các thuốc trừ sâu không có mẫu dương nào trong tập dữ liệu (cột FLAMENIR của Bảng 3), nên không thể huấn luyện được mô hình phát hiện/hồi quy.

PR-AUC dao động khá rộng, từ 0,455 (Cyantraniliprole) đến 0,953 (Chlopyrifos Methyl). Các chất có PR-AUC cao nhất (Chlopyrifos Methyl 0,953; Cyhalothrin 0,868) cũng là những chất được chọn ngưỡng quyết định cao hơn hẳn mức mặc định 0,5 (lần lượt 0,935 và 0,814) – vì mô hình đã tách biệt tốt hai lớp ngay từ ngưỡng thấp, thuật toán có thể đẩy ngưỡng lên để tăng Precision mà vẫn giữ Recall $\geq 0,9$. Phần lớn các chất còn lại có PR-AUC quanh mức 0,5–0,6 và ngưỡng thấp (0,08–0,2), đòi hỏi hạ ngưỡng sâu để đạt Recall mục tiêu, kéo theo Precision giảm còn khoảng 64–75% – phản ánh đúng bản chất khó của bài toán khi tín hiệu phổ NIR của các chất này chưa đủ đặc trưng để phân biệt rạch ròi ở độ phân giải 128 bước sóng của FLAMENIR. Một ngoại lệ đáng chú ý là Chlorantraniliprol: dù PR-AUC chỉ ở mức trung bình (0,571), chất này vẫn được chọn ngưỡng khá cao (0,678), cho thấy đường cong Precision-Recall của nó giữ Precision tốt cụ thể quanh điểm Recall = 0,9 dù PR-AUC tổng thể (lấy trung bình trên toàn miền Recall) không cao.

b/ Dự đoán hàm lượng

Nhờ kiểm định chéo K-Fold phân tầng (Mục 3.2.2) chia theo nhóm phân vị của nồng độ, 16/19 thuốc trừ sâu train được ở Bước 2, nhiều hơn 4 chất (Metalaxyl, Cyhalothrin,

Bảng 6. Kết quả dự đoán hàm lượng (trung bình 5-fold) – máy FLAMENIR

Thuốc trừ sâu	MSE	MAE	RMSE	R^2 (%)
Thiamethoxam	0,027	4,834	27,021	85,15
Permethrin	0,017	8,915	33,101	85,05
Metalaxyl	0,001	0,000	0,001	99,63
Azoxystrobin	0,007	13,955	66,604	90,63
Imidacloprid	0,028	1,081	2,936	83,44
Difenoconazole	0,007	4,539	24,545	93,65
Cypermethrin	0,013	0,064	0,203	92,93
Cyhalothrin	0,005	0,001	0,004	97,26
Chlorantraniliprol	0,013	0,000	0,001	93,61
Chlopyrifos Methyl	0,000	0,000	0,000	99,92
Emamectin benzoate	0,021	0,318	0,905	85,43
Chlorothalonil	0,015	401,527	1022,516	65,96
Triadimefon	NaN	NaN	NaN	NaN
Cyantraniliprole	0,004	3,682	7,926	94,37
Flutolanil	NaN	NaN	NaN	NaN
Indoxacarb	0,017	0,166	0,614	90,10
Abamectin	0,011	0,359	0,784	90,84
Propamocarb.HCL	NaN	NaN	NaN	NaN
Chlothianidin	0,022	4,988	23,219	86,40

các dòng tô vàng: chất chỉ có 2–3 mức nồng độ duy nhất trong toàn bộ tập dữ liệu (xem giải thích bên dưới), khiến MAE/RMSE thấp bất thường.

Chlorantraniliprol, Chlopyrifos Methyl) so với trước đây; chỉ còn 3 chất không có mẫu dương nào (Triadimefon, Flutolanil, Propamocarb.HCL) là không thể huấn luyện. R^2 dao động từ 65,96% (Chlorothalonil) đến 99,92% (Chlopyrifos Methyl), trung bình khoảng 90%. MAE và RMSE được báo cáo theo đơn vị nồng độ gốc (mg/kg, sau biến đổi ngược từ không gian log-chuẩn hóa, Mục 3.2.1) nên chênh lệch lớn giữa các chất phản ánh đúng thang đo tự nhiên của từng chất – ví dụ Chlorothalonil có nồng độ dao động rất rộng (0,132–6.196 mg/kg trong tập dữ liệu), nên MAE tuyệt đối (401,527) lớn hơn nhiều so với Metalaxyl hay Cyhalothrin, vốn có nồng độ chỉ trong khoảng 0,03–0,09 mg/kg.

Bốn chất tô vàng (Metalaxyl, Cyhalothrin, Chlorantraniliprol, Chlopyrifos Methyl) có MAE/RMSE gần 0 và R^2 trên 93% – cao bất thường so với các chất còn lại – không phải vì mô hình dự đoán xuất sắc hơn, mà vì nhãn nồng độ của các chất này trong dữ liệu gốc chỉ nhận 2–3 giá trị cố định (ví dụ Metalaxyl chỉ có đúng hai mức 0,032 và 0,08 mg/kg trên toàn bộ hơn 4.000 mẫu dương), thay vì biến thiên liên tục như Thiamethoxam (17 mức) hay Permethrin (20 mức). Khi đó bài toán hồi quy thực chất gần với phân loại rời rạc 2–3 lớp hơn là dự đoán một giá trị liên tục, nên sai số tuyệt đối tự nhiên thấp hơn hẳn và không phản ánh khả năng dự đoán nồng độ chi tiết của mô hình.

4.3. Máy OCEANFX

4.3.1. Phân loại rau củ quả

Độ chính xác trung bình của OCEANFX (96,04%) cao hơn FLAMENIR (93,98%, Bảng 4) khoảng 2 điểm %, phù hợp với việc OCEANFX có độ phân giải phổ cao hơn nhiều (2.136 so với 128 điểm bước sóng), cung cấp nhiều đặc trưng phân biệt hơn cho bài toán phân loại. Tuy nhiên độ

Bảng 7. Kết quả phân loại rau củ quả – máy OCEANFX

Fold	Accuracy	Precision	Recall	F1-Score
Fold 1	97,74%	97,73%	97,71%	97,72%
Fold 2	96,62%	96,37%	96,69%	96,52%
Fold 3	96,68%	96,75%	96,64%	96,69%
Fold 4	94,55%	94,67%	94,37%	94,51%
Fold 5	94,59%	94,39%	94,73%	94,53%
Trung bình	96,04$\pm$1,26 %	95,98$\pm$1,27 %	96,03$\pm$1,27 %	95,99$\pm$1,27 %

dao động giữa các fold lại lớn hơn FLAMENIR (từ 94,55% đến 97,74%, chênh khoảng 3,2 điểm %), có thể do một số loại rau củ quả vốn đã ít mẫu trên OCEANFX (Xà Lách, Cà Rốt – xem Bảng 2) phân bố không đều giữa các fold, khiến vài fold khó hơn hẳn các fold còn lại.

4.3.2. Dự đoán hàm lượng các thuốc trừ sâu có trong mẫu

a/ Phát hiện thuốc trừ sâu

Bảng 8. Kết quả phát hiện thuốc trừ sâu (trung bình 5-fold) – máy OCEANFX

Thuốc trừ sâu	Ngưỡng	Acc.	Prec.	Recall	F1	PR-AUC
Thiamethoxam	0,497	95,48%	87,01%	86,90%	86,95%	0,862
Permethrin	0,219	82,47%	74,52%	81,36%	76,66%	0,727
Metalaxyl	0,554	98,42%	89,25%	86,67%	87,90%	0,856
Azoxystrobin	0,469	95,67%	85,91%	86,07%	85,99%	0,833
Imidacloprid	0,320	96,78%	75,97%	80,83%	78,17%	0,590
Difenoconazole	0,437	95,46%	84,84%	85,08%	84,96%	0,809
Cypermethrin	0,316	94,49%	84,00%	87,65%	85,69%	0,819
Cyhalothrin	0,901	98,47%	97,92%	83,52%	89,33%	0,940
Chlorantraniliprol	0,819	98,93%	95,12%	79,50%	85,59%	0,845
Chlopyrifos Methyl	0,994	99,89%	99,93%	98,20%	99,05%	0,999
Emamectin benzoate	0,977	99,87%	99,93%	91,86%	95,53%	0,988
Chlorothalonil	0,466	96,34%	86,15%	83,28%	84,64%	0,798
Triadimefon			NaN (0 mẫu dương)			
Cyantraniliprole			NaN (0 mẫu dương)			
Flutolanil			NaN (0 mẫu dương)			
Indoxacarb	0,483	96,83%	83,33%	80,99%	82,10%	0,727
Abamectin	0,946	98,83%	98,70%	90,07%	93,91%	0,969
Propamocarb.HCL			NaN (0 mẫu dương)			
Chlothianidin	0,526	96,95%	83,73%	82,34%	83,02%	0,763

Ghi chú: NaN ứng với các thuốc trừ sâu không có mẫu dương nào trong tập dữ liệu (cột OCEANFX của Bảng 3), nên không thể huấn luyện được mô hình phát hiện/hồi quy. Ngưỡng quyết định được chọn theo cùng tiêu chí Recall mục tiêu $\geq 0,9$ mô tả ở Mục 3.2.2.

So với FLAMENIR, PR-AUC của OCEANFX cao hơn ở toàn bộ 15 thuốc trừ sâu train được trên cả hai máy (16 chất của FLAMENIR trừ Cyantraniliprole, chất duy nhất không train được trên OCEANFX), mức tăng trung bình khoảng 0,24 (ví dụ Azoxystrobin từ 0,529 lên 0,833; Cypermethrin từ 0,521 lên 0,819; mức tăng lớn nhất thuộc về Abamectin, từ 0,481 lên 0,969, và Emamectin benzoate, từ 0,532 lên 0,988). Đây là bằng chứng nhất quán cho thấy độ phân giải phổ cao hơn của OCEANFX mang lại lợi ích rõ rệt cho cả bài toán phân loại lẫn phát hiện thuốc trừ sâu, không chỉ riêng một tác vụ. Đặc biệt Chlopyrifos Methyl (PR-AUC 0,999) và Emamectin benzoate (0,988) gần như phân biệt hoàn hảo hai lớp trên máy này, phản ánh qua ngưỡng quyết định rất cao (0,994 và 0,977) mà vẫn giữ được Recall trên 91%.

b/ Dự đoán hàm lượng

Ghi chú: NaN của Triadimefon, Cyantraniliprole, Flu-

Bảng 9. Kết quả dự đoán hàm lượng (trung bình 5-fold) – máy OCEANFX

Thuốc trừ sâu	MSE	MAE	RMSE	R ² (%)
Thiamethoxam	0,019	3,299	19,236	93,86
Permethrin	0,006	8,029	27,778	90,90
Metalaxyl	0,000	0,000	0,001	99,75
Azoxystrobin	0,007	9,600	51,717	94,21
Imidacloprid	0,020	0,000	0,001	90,07
Difenoconazole	0,010	6,002	30,020	92,25
Cypermethrin	0,043	0,140	0,312	79,26
Cyhalothrin	0,006	0,001	0,005	97,12
Chlorantraniliprol	0,037	0,001	0,002	81,52
Chlopyrifos Methyl	0,000	0,000	0,000	99,88
Emamectin benzoate	NaN	NaN	NaN	NaN
Chlorothalonil	0,010	0,346	1,145	92,65
Triadimefon	NaN	NaN	NaN	NaN
Cyantraniliprole	NaN	NaN	NaN	NaN
Flutolanil	NaN	NaN	NaN	NaN
Indoxacarb	0,010	0,132	0,549	93,96
Abamectin	0,013	0,277	0,889	91,32
Propamocarb.HCL	NaN	NaN	NaN	NaN
Chlothianidin	0,007	3,322	13,428	96,51

các dòng tô vàng: chất chỉ có 2–3 mức nồng độ duy nhất trong toàn bộ tập dữ liệu, khiến MAE/RMSE thấp bất thường (xem giải thích ở Bảng 6).

tolanil, Propamocarb.HCL do không có mẫu dương nào (như ở Bảng 8); riêng Emamectin benzoate là trường hợp khác – toàn bộ 1.032 mẫu dương đều có cùng một giá trị nồng độ duy nhất (0,007 mg/kg), nên không đủ biến thiên để huấn luyện mô hình hồi quy.

Bốn chất Metalaxyl, Cyhalothrin, Chlorantraniliprol, Chlopyrifos Methyl tiếp tục là các trường hợp nhân nồng độ gần như rời rạc (2–3 mức) đã nêu ở Bảng 6, nên MAE/RMSE thấp bất thường trên cả hai máy. Riêng Imidacloprid chỉ bất thường trên OCEANFX: trong khi trên FLAMENIR chất này có 12 mức nồng độ trải rộng 0,017–27,4 mg/kg (MAE bình thường, 1,081), tập mẫu OCEANFX của Imidacloprid tình cờ chỉ chứa 3 mức nồng độ hẹp (0,017–0,024 mg/kg), khiến MAE gần như bằng 0 (0,000) dù cùng một chất, cùng một mô hình – minh chứng rõ ràng rằng MAE thấp phản ánh đặc điểm rời rạc của nhãn trong từng tập dữ liệu cụ thể, không phải sự khác biệt về khả năng của mô hình giữa hai máy.

14/19 thuốc trừ sâu train được ở Bước 2 trên OCEANFX (thiếu Emamectin benzoate và Cyantraniliprole so với FLAMENIR). So với FLAMENIR, kết quả trên OCEANFX không đồng loạt tốt hơn như ở bài toán phát hiện (Bảng 5 so với Bảng 8): 9/14 chất chung có R² cao hơn trên OCEANFX (đáng chú ý nhất là Chlorothalonil, tăng từ 65,96% lên 92,65%, và Chlothianidin, từ 86,40% lên 96,51%), nhưng 5 chất còn lại lại giảm, rõ nhất là Cypermethrin (92,93% xuống 79,26%) và Chlorantraniliprol (93,61% xuống 81,52%). Mức tăng trung bình qua 14 chất chỉ khoảng 2,8 điểm %, cho thấy độ phân giải phổ cao hơn của OCEANFX không mang lại lợi ích rõ rệt và nhất quán cho bài toán hồi quy nồng độ như đã thấy ở bài toán phân loại và phát hiện. Lưu ý mức tăng của riêng Imidacloprid (83,44% lên 90,07%) trong so sánh này không hoàn toàn công bằng, vì một phần đến từ đặc điểm nhãn rời rạc trên

OCEANFX vừa nêu trên, chứ không thuần túy do độ phân giải phổ.